João Pedro Santos Rodrigues

DETECÇÃO E MITIGAÇÃO INTELIGENTE DE ANOMALIAS EM REDES DEFINIDAS POR SOFTWARE COM GRANDES MODELOS DE LINGUAGEM OPEN SOURCE

EDITAL Nº 26/2026

Grande Área de Conhecimento do projeto (Tabela CNPq, conforme Quadro 3 deste edital): 1.00.00.00-3 CIÊNCIAS EXATAS E DA TERRA

Januária, MG

Fevereiro de 2026

RESUMO

Este trabalho propõe o desenvolvimento de um sistema baseado em LLMs open-source para detecção e mitigação de anomalias de performance em redes definidas por software. O sistema integra monitoramento contínuo de métricas, classificação por IA generativa e reconfiguração automática da rede em ciclo fechado, visando identificar fenômenos como congestionamento transiente, falhas de enlace e degradação de desempenho. A metodologia envolve a construção de um ambiente virtualizado em Linux, a geração controlada de cenários anômalos e o uso de técnicas de Ajuste Fino em Parâmetros (PEFT), como LoRA. Espera-se avaliar a viabilidade técnica da abordagem e compará-la a métodos tradicionais, contribuindo para o avanço de redes autônomas baseadas em IA.

Palavras chave: Redes Definidas por Software; Anomalias em Redes; Grande Modelos de Linguagem; Redes Autônomas.

Introdução

Redes de computadores modernas são caracterizadas por alta complexidade, heterogeneidade de aplicações e demandas cada vez mais rigorosas de desempenho, confiabilidade e segurança (LIU *et al*., 2024). Nesse contexto, a identificação e a classificação de fenômenos anômalos de rede como, congestionamento, aumento excessivo de latência, perda de pacotes, falhas de enlace e padrões de tráfego atípicos, tornam-se atividades fundamentais para a operação eficiente de sistemas computacionais distribuídos (LIU *et al.,* 2024),(KALAN, 2018).

Tradicionalmente, a análise de anomalias e a configuração de redes dependem de intervenção manual e conhecimento especializado, o que torna os processos propensos a erros, demorados e com baixa agilidade para adaptação em tempo real (ARAÚJO, 2024), (ZHOU *et al*, 2025). Embora eficazes em cenários específicos, os sistemas baseados em assinaturas ou regras pré-definidas são frequentemente reativos e possuem capacidade limitada para detectar ameaças novas ou desconhecidas (DIAF, 2024),(NEUPANE, 2018).

Nos últimos anos, de acordo com Liu *et al.* 2024, modelos de IA generativa, em especial modelos de linguagem de grande porte (LLMs), têm demonstrado capacidades avançadas de interpretação, raciocínio contextual e generalização a partir de descrições textuais e dados estruturados. Diferentemente de classificadores tradicionais, esses modelos são capazes de combinar múltiplas informações, lidar com incertezas e produzir não apenas uma decisão, mas também uma justificativa textual para essa decisão. Essas características abrem novas possibilidades para sua aplicação em domínios técnicos, como a análise de redes de computadores (LIU *et al.*, 2024).

Apesar do crescente interesse, o uso de modelos generativos para a classificação de anomalias ainda enfrenta desafios como o alto custo computacional e a necessidade de integração com sistemas legados. Há uma lacuna na investigação sobre como esses modelos podem operar como classificadores inteligentes baseados em métricas resumidas de tráfego. (LIU *et al.*, 2024).

Para superar essas barreiras, ambientes de rede virtualizados, como emuladores (Mininet, GNS3, PNETLab) e controladores SDN, oferecem um cenário controlado e repetível para a criação de condições anômalas e coleta sistemática de métricas (KALAN, 2018). O paradigma SDN, ao separar o plano de controle do plano de dados, fornece a agilidade necessária para que agentes de IA percebam o estado da rede e executem ações de otimização ou segurança de forma autônoma (ZORAIDA, 2024).

Diante desse contexto, este projeto propõe avaliar o uso de IA generativa para a classificação de fenômenos anômalos, investigando se modelos como GPT conseguem identificar corretamente intrusões e anomalias de desempenho. Assim, espera-se que o uso de LLMs contribua para o desenvolvimento de redes mais resilientes, inteligentes e capazes de se auto-otimizar em tempo real.

Objetivos

Objetivo Geral

Desenvolver um sistema autônomo baseado em LLMs open-source e Avaliar a viabilidade para detectar anomalias de performance em SDN, como congestionamento transiente, falhas de enlace e degradação espectral, e mitigar via reconfiguração proativa de VNT e roteamento.

Objetivos específicos

- Identificar e definir um conjunto representativo de fenômenos anômalos relevantes em redes de computadores, considerando aspectos de desempenho e operação da rede.
- Identificar as propriedades de aprendizado e organização de tokens em uma modelagem para detecção de anomalias.
- Projetar e implementar um ambiente de rede virtualizada que permita a geração controlada e reprodutível de diferentes cenários de anomalia.
- Desenvolver um pipeline de classificação baseado em IA generativa, capaz de receber métricas resumidas de tráfego e produzir a classificação do fenômeno anômalo correspondente.
- Implementar métodos de classificação de referência (baselines), como regras heurísticas ou modelos tradicionais de aprendizado de máquina, para fins de comparação.
- Avaliar o desempenho da abordagem baseada em IA generativa em termos de acurácia, consistência e tempo de resposta.
- Analisar qualitativamente os resultados obtidos, identificando limitações, padrões de erro e potencial de interpretabilidade das decisões geradas pelo modelo.

Referencial Teórico

A evolução das redes de computadores, especialmente com o advento do 5G e das futuras redes 6G, trouxe desafios que vão além da segurança cibernética, concentrando-se na manutenção de níveis rigorosos de vazão (throughput), latência e eficiência espectral (ARAUJO, 2024), (BARIAH, 2020). Fenômenos anômalos de rede, como o congestionamento transiente, falhas de enlace e degradação de sinal, impactam diretamente a performance e a confiabilidade dos sistemas distribuídos (LIU *et al*., 2024), (ALI, 2023). Tradicionalmente, o monitoramento dessas métricas dependia de protocolos como o SNMP, que opera em intervalos fixos e carece de visibilidade em tempo real para ambientes dinâmicos (RAFIQUE, 2018).

Neste cenário, a análise de anomalias de performance, como variações na frequência e ocupação de canais, torna-se vital. Em redes ópticas, por exemplo, anomalias como o "desvio de filtro" *(filter shift)* e o "estreitamento de filtro" (*filter tightening*) podem distorcer o espectro do sinal, afetando a simetria da frequência central e degradando a qualidade da transmissão. A detecção proativa dessas anomalias permite a reconfiguração da Topologia de Rede Virtual (VNT) antes que ocorra uma interrupção total do serviço. (RAFIQUE, 2018)

A integração de Large Language Models (LLMs) no Gerenciamento e Operações de Rede (NO&M) oferece uma nova abordagem para interpretar métricas complexas de tráfego (LONG, 2025). Diferente de modelos estatísticos rígidos, os LLMs e modelos baseados em Transformers conseguem capturar relações contextuais e padrões temporais em fluxos de rede, identificando desvios nos padrões operacionais normais com alta precisão (LIU et al., 2024), (LONG, 2025). Esses modelos permitem que a rede perceba o estado de parâmetros como o ganho do amplificador, a temperatura do sistema e o volume de tráfego, correlacionando-os para localizar a raiz de uma queda de velocidade ou perda de pacotes.

As Redes Definidas por Software (SDN) representam um paradigma emergente que separa o plano de controle do plano de dados, permitindo que a lógica de rede seja gerenciada de forma logicamente centralizada por um controlador baseado em software (KALAN, 2019), (HAJI, 2021). Esta arquitetura oferece agilidade e flexibilidade, permitindo que operadores implementem estratégias de roteamento inovadoras e coletem informações da rede em tempo real (ZORAIDA, 2024). Complementarmente, a Virtualização de Funções de Rede (NFV) substitui hardwares proprietários por instâncias de software rodando em máquinas virtuais, o que facilita a implementação de funções como firewalls e sistemas de detecção de intrusão (IDS) de maneira escalável. A união desses conceitos permite a

auto-reconfiguração rápida da rede para responder a variações de carga ou falhas (SHEN, 2023).

Segundo Fan Liu (2024) , o gerenciamento de redes evoluiu de processos manuais, propensos a erros e difíceis de escalar, para sistemas inteligentes e autônomos. Os Large Language Models (LLMs), como GPT-4, BERT e Llama, propuseram um salto significativo nesta área devido à sua capacidade de processar vastos volumes de dados não estruturados e realizar raciocínio contextual.

> *LLMs can be categorized into two main types: open-source and closed-source models. Open-source LLMs, such as Llama, Falcon, [...], are typically free and offer trans-parency, allowing researchers to customize and fine-tune. [...]. Closed-source LLMs, often referred to as commercial LLMs such as ChatGPT, Gemini and Claude typically require payment but provide state-of-the-art performance, along with support and infrastructure from commercial entities.*(LIU *et al., 2024)*

Estes modelos são construídos sobre a arquitetura Transformer, que utiliza mecanismos de self-attention para capturar dependências de longo alcance em sequências de dados, sendo ideais para tarefas que envolvem logs de rede complexos e identificação de anomalias (ANGI *et al.,* 2025). A integração de LLMs permite o desenvolvimento de redes baseadas em intenções (Intent-Based Networking - IBN), onde objetivos definidos em linguagem natural são traduzidos autonomamente em configurações técnicas (ZHOU *et al., 2024*).

A adoção de IA em operações críticas ultrapassa a barreira da opacidade dos modelos tradicionais de caixa-preta, onde a lógica por trás de uma decisão não é clara para o analista (DANILEVSKY *et al.*, 2020). A Inteligência Artificial Explicável (XAI) é essencial para fornecer transparência e aumentar a confiabilidade dos sistemas de segurança. Protótipos como o HuntGPT integram agentes de conversação baseados em LLM com frameworks de explicabilidade (ALI, 2023), entregando detecções em um formato compreensível e fornecendo justificativas textuais que auxiliam as equipes de resposta a incidentes na tomada de decisões rápidas e informadas.

Para viabilizar o ajuste de LLMs em ambientes com hardware limitado, podes-e utilizar técnicas de Ajuste Fino Eficiente em Parâmetros (Parameter-Efficient Fine-Tuning – PEFT), com destaque para o LoRA (Low-Rank Adaptation) e o QLoRA (Quantized Low-Rank Adaptation).

O método LoRA baseia-se na hipótese de que as atualizações de pesos necessárias durante a adaptação de um modelo possuem um ranking intrínseco baixo. Essa característica permite que a atualização da matriz de pesos original seja representada matematicamente por meio de uma decomposição de baixo ranking [Hu et al., 2021]. Dessa

forma, o LoRA possibilita a adaptação de modelos de linguagem de grande escala a domínios específicos sem a necessidade de retreinar todos os seus parâmetros.

Formalmente, o processo pode ser expresso como:

$$W' = W0 + BA$$

Onde:
W'': matriz de pesos atualizada
$W0$: pesos pré-treinados originais (congelados)
B: matriz de dimensões d × r
A: matriz de dimensões r × k
r: rank baixo (tipicamente 8-64)

Todo esse procedimento, os pesos pré-treinados do modelo são mantidos fixos, enquanto as matrizes A e B são inseridas como parâmetros treináveis em cada camada da arquitetura Transformer. Essa estratégia reduz significativamente o número de parâmetros ajustados durante o treinamento e, consequentemente, a demanda por memória de vídeo (VRAM). Uma vantagem relevante do LoRA é a ausência de impacto na latência de inferência (Hu *et al*., 202).

O QLoRA representa uma evolução direta do LoRA, ampliando ainda mais a eficiência de memória e possibilitando o ajuste fino de modelos com até 65 bilhões de parâmetros utilizando uma única GPU de 48 GB, sem degradação significativa de desempenho em relação a modelos treinados em precisão de 16 bits (Dettmers *et al*., 2023).

Metodologia

Etapa 1: Revisão de Literatura

Nessa etapa serão revisados os conceitos norteadores das tecnologias que serão empregadas na pesquisa, tais como Fine-tuning, Criação de ambientes virtualizados de rede, Modelagem do Plano de Dado e Plano de Controle, Integração de Dados e Processos. Além da avaliação de qual modelo mais se adapta a necessidade do projeto.

Etapa 2: Preparação de Dado para Treinamento

Além dos cenários anômalos gerados no ambiente virtualizado, este trabalho utilizará datasets públicos amplamente reconhecidos na literatura para complementar o estudo, validar os modelos propostos e permitir comparações com trabalhos relacionados. O uso de

múltiplas bases de dados contribui para avaliar a capacidade de generalização dos modelos de IA generativa em diferentes contextos de tráfego e tipos de anomalia.

Dataset	Descrição	Ataques/Anomalias	Tamanho	Fonte
UNSW-NB15	Tráfego real + sintético; 49 features (dur., bytes, ports).	DDoS, worms, exploits.	~2.5M fluxos	sol.sbc
CSE-CIC-IDS2018	Alta diversidade; maioria benigna.	Infiltration, botnet, DDoS.	~16M registros CSV	kaggle
Synthetic SDN	Fluxos sintéticos para SDN/IoT; labels 0(normal)/1(anômalo).	DDoS, scan, exfiltração.	10k registros	data.mendeley

Tabela 1: Datasets para validação e generalização do treinamento

Os datasets selecionados serão utilizados de forma complementar, com os seguintes objetivos:

- Análise exploratória das características e padrões de tráfego associados a diferentes tipos de anomalia.
- Conversão de atributos numéricos em representações textuais estruturadas, adequadas para entrada em modelos de linguagem.
- Treinamento e ajuste fino dos modelos de IA generativa utilizando técnicas PEFT, quando aplicável.
- Validação cruzada dos resultados obtidos no ambiente virtualizado, verificando a consistência das classificações em bases de dados consolidadas.

Etapa 3: Definição de Anomalias

A geração de anomalias de performance será realizada de forma controlada e reprodutível. Serão induzidos cenários representativos de congestionamento transiente, falhas de enlace e degradação espectral. O congestionamento será simulado por meio da limitação artificial de banda e da injeção de tráfego intenso, enquanto falhas de enlace serão representadas por interrupções temporárias ou degradações progressivas na capacidade dos links. Durante a execução dos experimentos, o controlador SDN realizará a coleta contínua de métricas de desempenho da rede, incluindo throughput, latência média, jitter, taxa de perda

de pacotes e utilização de enlaces. Em seguida, os dados numéricos serão normalizados e convertidos em uma representação semiestruturada, que combina valores quantitativos com descrições textuais padronizadas. Essa etapa é fundamental para alinhar os dados de entrada ao formato esperado pelos modelos de linguagem, preservando o contexto operacional da rede.

Etapa 4: Contextualização e Treinamento do LLM

As métricas resumidas de tráfego serão inseridas em prompts estruturados, que descrevem o estado da rede e apresentam um conjunto fechado de classes correspondentes aos fenômenos anômalos considerados, e das quais serão treinadas separadamente e avaliadas em conjunto. A inferência será realizada pelo modelo selecionado na primeira etapa, que produzirá como saída a classe da anomalia identificada e, opcionalmente, uma justificativa textual para a decisão. Essa abordagem busca explorar a capacidade dos LLMs de realizar raciocínio contextual, ao mesmo tempo em que reduz ambiguidades por meio da restrição explícita do espaço de decisão.

Etapa 5: Implementação e Validação

A implementação do sistema será conduzida de forma incremental, com foco na construção de um protótipo funcional capaz de operar em ciclo fechado, desde a coleta de métricas até a mitigação de anomalias por reconfiguração. Inicialmente, será configurado o ambiente de emulação em Linux. Com a infraestrutura de coleta consolidada, será implementado o pipeline de classificação baseado na estrutura da IA. Essa etapa inclui o desenvolvimento de um componente responsável pela construção de prompts estruturados a partir das métricas agregadas, restringindo explicitamente o conjunto de classes possíveis e definindo um formato de saída padronizado para a decisão do modelo. A inferência será realizada utilizando um LLM open-source, encerrando-se em um módulo de decisão e mitigação, responsável por mapear cada classe de anomalia para um conjunto de ações corretivas executadas pelo controlador SDN.

Resultados esperados

Espera-se demonstrar a viabilidade do uso de modelos de IA generativa para a detecção de anomalias de performance em redes definidas por software, alcançando níveis satisfatórios de acurácia e consistência na classificação de fenômenos como congestionamento, falhas de enlace e degradação de desempenho. Espera-se também que o ajuste fino com técnicas como LoRA ou QLoRA proporcione melhoria em relação à abordagem zero-shot, mantendo os requisitos computacionais compatíveis com infraestrutura acadêmica padrão. No âmbito

da mitigação, espera-se evidenciar que a integração entre o módulo de classificação e o controlador SDN permite reconfigurações proativas capazes de reduzir o impacto das anomalias nas métricas de desempenho da rede. Por fim, espera-se produzir um protótipo funcional validado experimentalmente, além de uma análise comparativa entre IA generativa e métodos tradicionais, contribuindo para o entendimento do uso de LLMs em arquiteturas de redes autônomas.

Cronograma de atividades

Etapa	Atividade	Mês 1–4	Mês 5–7	Mês 8–10	Mês 11–13	Mês 14–16	Mês 17–20
1	Revisão bibliográfica aprofundada (SDN, LLMs, Anomalias, PEFT)	X	X				
2	Definição final das anomalias e escopo experimental	X					
3	Configuração do ambiente Linux SDN		X				
4	Implementação do módulo de coleta e agregação de métricas		X	X			
5	Implementação do gerador de cenários anômalos			X			
6	Implementação dos baselines tradicionais			X	X		
7	Desenvolvimento do pipeline LLM (zero-shot)				X		
8	RAG com LoRA/QLoRA				X	X	
9	Implementação do módulo de decisão e mitigação SDN					X	
10	Integração completa (ciclo fechado)					X	
11	Execução dos experimentos e coleta de resultados					X	X
12	Análise quantitativa e qualitativa						X

Tabela 2: Cronograma de atividades do projeto em 20 meses

Viabilidade técnica e financeira

A viabilidade técnica do presente projeto fundamenta-se na utilização de tecnologias consolidadas, amplamente documentadas e suportadas por comunidades ativas de pesquisa e desenvolvimento. A infraestrutura necessária para a implementação do sistema proposto pode ser integralmente executada em ambiente Linux, utilizando ferramentas open-source como Mininet, Open vSwitch e controladores SDN programáveis, o que elimina a necessidade de hardware especializado ou licenças proprietárias.

Do ponto de vista computacional, o uso de modelos de linguagem open-source permite maior flexibilidade e controle sobre o processo de inferência e ajuste fino. Modelos na faixa de 7 a 13 bilhões de parâmetros são compatíveis com GPUs profissionais. Além disso, pode-se utilizar ambientes de desenvolvimento integrado (IDE) baseado em navegador que disponibilizam GPU para desenvolvimento, como Kaggle, que é gratuito e disponibiliza duas GPU T4. Assim, considerando a maturidade das tecnologias empregadas, a disponibilidade de ferramentas open-source, a aplicabilidade de técnicas de otimização de modelos e a possibilidade de execução em infraestrutura computacional acadêmica, conclui-se que o projeto apresenta elevada viabilidade técnica para implementação no período proposto.

Referências Bibliográficas

ALI, Tarek; KOSTAKOS, Panos. HuntGPT: **Integrating machine learning-based anomaly detection and explainable AI with large language models (LLMs).** arXiv preprint arXiv:2309.16021, 2023.

ANGI, Antonino; SACCO, Alessio; MARCHETTO, Guido. **LLNet: An Intent-Driven Approach to Instructing Softwarized Network Devices Using a Small Language Model**. IEEE, 2024.

ARAUJO, Aramis Sales et al. **An Agentic Approach For Dynamic Software-Defined Network Management Using Large Language Models**. Campina Grande: UFCG, 2024.

BARIAH, Lina et al.,. **A Prospective Look: Key Enabling Technologies, Applications and Open Research Topics in 6G Networks**. IEEE Access, v. 8, p. 101912-101947, 2020.

DANILEVSKY, Marina; QIAN, Kun; AHARONOV, Ranit; KATSIS, Yannis; KAWAS, Ban; SEN, Prithviraj. **A Survey of the State of Explainable AI for Natural Language Processing**. arXiv preprint arXiv:2010.00711, 2020.

DETTMERS, Tim et al. **QLoRA: Efficient Finetuning of Quantized LLMs. Advances in Neural Information Processing Systems** (NeurIPS 2023), v. 36, 2024.

DIAF, Alaeddine et al. **Beyond Detection: Leveraging Large Language Models for Cyber Attack Prediction in IoT Networks**. IEEE, 2024.

HU, Edward J. et al. **LoRA: Low-Rank Adaptation of Large Language Models**. arXiv preprint arXiv:2106.09685, 2021.

KALAN, Reza Shokri; SAYIT, Muge; BEGEN, Ali C. **Implementation of SAND Architecture Using SDN**. IEEE, 2018

LIU, Fan; FARKIANI, Behrooz; CROWLEY, Patrick. **A Survey on Large Language Models for Network Operations & Management: Applications, Techniques, and Opportunities**. arXiv preprint, 2024.

LONG, Sifan; TAN, Jingjing; MAO, Bomin; TANG, Fengxiao; LI, Yangfan; ZHAO, Ming; KATO, Nei. **A survey on intelligent network operations and performance optimization based on Large Language Models**. arXiv preprint arXiv:2404.18373, 2024

NEUPANE, Kishan; HADDAD, Rami; CHEN, Lei. **Next generation firewall for network security: a survey.** In: SoutheastCon 2018. IEEE, p. 1-6, 2018.

SHEN, Xuemin et al. **Holistic network virtualization and pervasive network intelligence for 6G. IEEE Communications Surveys & Tutorials**, v. 24, n. 1, p. 1-30, 2021

ZHOU, Anni; SONG, Yuchen; ZHANG, Yao; ZHANG, Min; WANG, Danshi. **Large Language Model-Driven AI Agent in SDN Controller Towards Intent-Based Management of Optical Networks.** Beijing: State Key Laboratory of Information Photonics and Optical Communications, 2024

ZORAIDA, Berty Smitha Evelin; INDUMATHI, Ganesan. **A Comparative Study on Software-Defined Network with Traditional Networks**. TEM Journal, v. 13, n. 1, p. 129-138, 2024