11McKEOWN et al, 2008 110XIA et al, 2015 114MEDVED et al, 2014 115BERDE et al, 2014 116NTT Laboratories. Ryu SDN Framework - Open-source SDN Platform Software. NTT Technical Review, 2014 12GUDE et al, 2008 122PORRAS et al, 2012 123LI et al, 2016 124BHUIYAN et al, 2023 126LATIF et al, 2022 127CHIOSI et al, 2012 128ETSI NFV ISG. GS NFV 002 V1.1.1: Network Functions Virtualisation (NFV); Architectural Framework. ETSI et al, 2013 129ETSI NFV ISG. GS NFV-MAN 001 V1.1.1: Network Functions Virtualisation (NFV); Management and Orchestration. ETSI et al, 2014 130MIJUMBI et al, 2015 131MIJUMBI et al, 2016 132LAGHRISSI et al, 2019 133LEIVADEAS et al, 2022 134MORALES et al, 2017 135VELASCO et al, 2022 14LANTZ et al, 2010 15PFAFF et al, 2015 19KREUTZ et al, 2015 21BRUTLAG, 2000 210BHUYAN et al, 2014 212BUCZAK et al, 2016 213CORTES et al, 1995 217CARUANA et al, 2006 22ROBERTS, 1959 222HODO et al, 2017 224ALDUAILIJ et al, 2022 225NEGANDHI et al, 2016 226WILLEMS et al, 2023 227SHEHAB et al, 2024 229STANIFORD-CHEN et al, 1996 231CANNADY, 1998 232LAKHINA et al, 2004 25MOAYEDI et al, 2008 27FONDO-FERREIRO et al, 2026 28CHANDOLA et al, 2009 29AHMED et al, 2016 31LIU et al, 2025 310TOUVRON et al, 2023 311TOUVRON et al, 2023 312JIANG et al, 2023 313ALMAZROUEI et al, 2023 314BAI et al, 2023 315YANG et al, 2024 316BIGSCIENCE WORKSHOP et al, 2022 317GEMMA TEAM (Google DeepMind). Gemma: Open Models Based on Gemini Research and Technology. arXiv preprint arXiv:2403.08295, 2024 319VASWANI et al, 2017 32LIU et al, 2024 320OUYANG et al, 2022 321WEI et al, 2022 324HOSSAIN et al, 2025 325SDN-Xplain: LLM-Driven Anomaly Detection and Human-Interpretable Explanation in SDN. SKKU IoT Lab / KICS Winter 2026 (preprint), 2026 327Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN. arXiv/ResearchGate preprint, 2025 33BOATENG et al, 2024 332ADANZA et al, 2025 333Towards Intent-Based Network Management: Large Language Models for Intent Extraction in 5G Core Networks. IEEE / GenAI Net research library, 2024 334Exploring LLM-Based Agents for Root Cause Analysis. ACM SIGMETRICS / arXiv:2403.04123, 2024 335Empowering AIOps: Leveraging Large Language Models for IT Operations Management. arXiv:2501.12461, 2025 336WANG et al, 2025 337LLM-Driven Multi-Agent Framework for Autonomous Network Slice Management. IEEE, 2026 338CHEN et al, 2024 34HANG et al, 2024 35HUANG et al, 2024 36HONG et al, 2025 37ZHANG et al, 2025 39TANG et al, 2024 41HU et al, 2021 411HU et al, 2023 412ZHANG et al, 2024 414DING et al, 2022 415HAN et al, 2024 42DETTMERS et al, 2023 422BROWN et al, 2005 424ACHIAM et al, 2023 425MENG et al, 2025 426GINIGE et al, 2024 427CUI et al, 2025 43ZHANG et al, 2023 431SUI et al, 2024 432HEGSELMANN et al, 2023 44LIU et al, 2024 45HOULSBY et al, 1902 49LIU et al, 2022 51ESSENCIAL Danilevsky et al, 2010 511ESSENCIAL Ali et al, 2023 512ESSENCIAL1 Neupane et al, 2022 517RECOMENDADO Sarker, 2024 52ESSENCIAL Arrieta et al, 2019 520COMPLEMENTAR Houssel et al, 2024 521COMPLEMENTAR Pizarro et al, 2025 522COMPLEMENTAR Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN. arXiv:2510.23313 (preprint), 2025 53ESSENCIAL Ribeiro et al, 2016 531ESSENCIAL Kadavath et al, 2022 532RECOMENDADO Guo et al, 2017 533RECOMENDADO Lin et al, 2022 534RECOMENDADO

et al, 2010

Detecção e Mitigação Inteligente de Anomalias em Redes Definidas por Software com Grandes Modelos de Linguagem Open Source: correlação entre o Projeto de Pesquisa e o Sistema Implementado (NOC Lite)

Estudo de correlação elaborado a partir do Projeto de Pesquisa de Rodrigues (20

Artigo técnico-científico — revisão integrati

Julho de 2026

Abstract

Este artigo correlaciona o projeto de pesquisa que propõe a detecção e a mitigação inteligente de anomalias em redes definidas por software (SDN) por meio de grandes modelos de linguagem (LLMs) *open source* ajustados por PEFT/LoRA, com o sistema efetivamente implementado – o *NOC Lite*. Partindo de uma revisão da literatura estruturada em seis eixos (SDN/NFV, anomalias por ML, LLMs para NetOps, PEFT/LoRA, XAI e datasets), descreve-se a arquitetura e o pipeline de classificação do sistema construído, composto por três classificadores (heurístico, árvore de decisão e IA generativa via Google Gemini). Em seguida, apresenta-se o mapeamento artigo×sistema e a taxonomia de gaps estruturais – destacando-se a ausência de SDN, o uso de modelo fechado em vez de LLM *open source*, a inexistência de ajuste fino LoRA/QLoRA, a falta de mitigação em ciclo fechado e a dependência exclusiva de dados sintéticos. Discutem-se as convergências preservadas (baselines, tokenização, justificativa textual, métricas de latência) e propõem-se diretrizes de arquitetura para o alinhamento futuro, incluindo um ciclo fechado com LLM local, LoRA e módulo de mitigação. Conclui-se que o NOC Lite realiza parcela da intenção do projeto, mas exige evolução arquitetural substantiva nos eixos centrais para aproximar-se da proposta norteadora.

Palavras-chave: Redes Definidas por Software; Anomalias de Rede; Grandes Modelos de Linguagem; PEFT/LoRA; Inteligência Artificial Explicável.

1 Introdução

Redes de computadores modernas apresentam alta complexidade, heterogeneidade de aplicações e demandas rigorosas de desempenho, confiabilidade e segurança Rodrigues, João Pedro Santos, 2026. Nesse contexto, a identificação e a classificação de fenômenos anômalos – congestionamento transiente, falhas de enlace, degradação de desempenho – tornam-se atividades fundamentais para a operação eficiente de sistemas distribuídos . Tradicionalmente, a análise de anomalias depende de intervenção manual e conhecimento especializado, o que a torna propensa a erros e com baixa agilidade de adaptação em tempo real . Modelos baseados em assinaturas ou regras predefinidas são frequentemente reativos e possuem capacidade limitada para detectar ameaças desconhecidas .

Nos últimos anos, grandes modelos de linguagem demonstraram capacidades de interpretação, raciocínio contextual e generalização a partir de descrições textuais e dados estruturados . Diferentemente de classificadores tradicionais, tais modelos conseguem combinar múltiplas informações, lidar com incertezas e produzir não apenas uma decisão, mas também uma justificativa textual . O paradigma SDN, ao separar o plano de controle do plano de dados, fornece a agilidade necessária para que agentes de IA percebam o estado da rede e executem ações de otimização ou segurança de forma autônoma .

O projeto de pesquisa norteador Rodrigues, João Pedro Santos, 2026 propõe desenvolver um sistema autônomo baseado em LLMs *open source* (ex.: Llama, Falcon) e em ajuste fino eficiente de parâmetros (PEFT), notadamente LoRA/QLoRA, para detectar anomalias de performance em SDN e mitigá-las via reconfiguração proativa de topologia virtual (VNT) e roteamento, em ciclo fechado. Contudo, o sistema implementado – o *NOC Lite* – monitora *hosts* genéricos (endereços IP/DNS) por sondas ICMP/TCP/HTTP/DNS/SNMP, emprega o modelo fechado Google Gemini como classificador generativo e não realiza mitigação nem reconfiguração de rede.

Problema e gap. Há uma distância estrutural entre a proposta do projeto e o sistema construído. Essa distância motiva a presente análise, que tem por objetivos: (i) expor o referencial teórico das seis áreas de conhecimento envolvidas; (ii) descrever o sistema implementado e seu pipeline de classificação; (iii) apresentar o mapeamento projeto×sistema e a taxonomia

de gaps; (iv) discutir convergências, limitações e ameaças à validade; e (v) propor diretrizes de arquitetura para o alinhamento futuro. A contribuição deste artigo é, portanto, a primeira caracterização sistemática e fundamentada em evidência de código da lacuna entre uma proposta de pesquisa de LLMs *open source* para SDN e sua implementação concreta.

2 Referencial Teórico e Revisão da Literatura

A fundamentação deste trabalho articula seis eixos de conhecimento, sintetizados a partir de revisão de literatura estruturada, com 122 referências efetivamente citadas e validadas neste artigo.

2.1 Método e Corpus de Análise

A seleção do corpus seguiu um procedimento de revisão integrativa . Partiu-se de seis áreas de conhecimento (Eixos 1–6), mapeadas a partir do Projeto de Pesquisa norteador Rodrigues, João Pedro Santos, 2026 e de relatórios de análise de código do sistema NOC Lite: (1) SDN/NFV; (2) detecção e classificação de anomalias por ML tradicional; (3) LLMs *open source* e modelos de linguagem para NetOps; (4) fine-tuning eficiente de LLMs (PEFT/LoRA/QLoRA); (5) IA explicável (XAI); e (6) geração de cenários anômalos e *datasets* públicos. Como critérios de inclusão, admitiram-se obras primárias (artigos, *preprints* e relatórios técnicos) diretamente relacionadas a um dos seis eixos e com relevância para a análise arquitetural realizada; excluíram-se trabalhos fora do escopo de detectação/mitigação de anomalias em redes e fontes sem validação verificável. O corpus final compreende 122 fontes efetivamente citadas, distribuídas pelos seis eixos, consolidadas em uma única lista de referências ordenada alfabeticamente conforme a ABNT NBR 6023.

2.2 Redes Definidas por Software e Virtualização de Funções de Rede

O paradigma SDN desacopla o plano de controle do plano de dados por meio de um protocolo *southbound* padronizado (OpenFlow) e de controladores programáveis (NOX , POX, Ryu , OpenDaylight , ONOS). Essa centralização lógica cria uma única fonte de verdade e uma superfície de programação que, simultaneamente, facilita a automação e introduz novas superfícies de ataque no plano de controle . A emulação (Mininet , Open

vSwitch) viabiliza a geração controlada de cenários anômalos . Surveys definitivos consolidam a taxonomia e os desafios de segurança da SDN .

Complementarmente, a Virtualização de Funções de Rede (NFV), institucionalizada pelos *white papers* e pelo *framework* arquitetural da ETSI , e revisada por Mijumbi et al. e Laghrissi & Taleb , estende o paradigma ao ciclo de vida de funções virtualizadas e sua orquestração (MANO). Sobre esse alicerce, o *Intent-Based Networking* (IBN) emerge como a camada de gestão que traduz objetivos de alto nível em configurações concretas e as garante por meio de laços fechados . Trabalhos como Morales et al. e a survey de Panayiotou et al. antecipam a reconfiguração proativa da topologia virtual orientada a dados e ML. A detecção de anomalias em SDN transita, assim, de métodos clássicos de ML para a integração de LLMs *open source* ajustados por LoRA/QLoRA.

2.3 Detecção e Classificação de Anomalias por Métodos Tradicionais

A literatura consolida que métodos estatísticos (cartas EWMA , Holt-Winters , ARIMA/SARIMA) e classificadores de ML clássico (SVM , *Random Forest* , árvores de decisão , redes rasas) formam o arcabouço de *baselines* sobre o qual a detecção moderna é avaliada. Surveys consagrados reforçam que heurísticas de limiar e modelos estatísticos são insubstituíveis como referência de comparação por serem interpretáveis e leves. Para os tipos de anomalia do sistema, há corpus dedicado: DDoS é coberto por baselines de árvore/RF ; varredura de portas possui precedentes heurísticos e de ML ; exfiltração é abordada sobre metadados de fluxo ; e congestionamento/falha de enlace encontra raiz em detecção estatística de séries temporais .

2.4 LLMs Open Source e Modelos de Linguagem para NetOps

Surveys dedicados mapeiam a aplicação de LLMs à operação e gestão de redes (NO&M/NetOps) . O ecossistema de modelos *open source* – LLaMA/Llama 2 , Mistral 7B , Falcon , Qwen/Qwen2.5 , BLOOM e, sobretudo, Gemma (derivado da tecnologia Gemini) – oferece pesos e licenças que tornam viável a substituição de modelos fechados por alternativas locais e ajustáveis . A arquitetura Transformer , o alinhamento por RLHF e o *Chain-of-Thought* (CoT) fundamentam, respectivamente, a capacidade de raciocínio, de seguir instruções e de produzir justificativa textual. Aplicações concretas incluem detecção de anomalias em SDN , IBN orientado a LLM e agentes de rede

autônomos .

2.5 Fine-Tuning Eficiente de LLMs (PEFT): LoRA, QLoRA

O ajuste fino eficiente (PEFT) – liderado por LoRA e estendido por QLoRA , AdaLoRA e DoRA – é a via consagrada para adaptar LLMs *open source* a domínios específicos com orçamento de hardware modesto, reduzindo ordens de magnitude de parâmetros treináveis sem overhead de inferência . Frameworks como LLM-Adapters e LLaMA-Adapter demonstram que LLMs 7B ajustados por PEFT igualam ou superam modelos 175B em *zero-shot*. No domínio de tráfego de rede, NetGPT , TrafficGPT e TrafficLLM mostram que LLMs podem ser ajustados (com tokenização de domínio) para entender e classificar tráfego. A base *few-shot/zero-shot* (Brown , Wei , Achiam) legitima o uso de LLMs sem ajuste de pesos, mas a literatura documenta que PEFT tipicamente supera o *in-context learning* em custo e acurácia .

2.6 Inteligência Artificial Explicável (XAI)

A XAI é requisito fundamental para a adoção confiável de detectores em domínios de alta responsabilidade . Em NLP, o survey de Danilevsky et al. sistematiza como modelos de linguagem produzem explicações; Ribeiro et al. (LIME) e Lundberg & Lee (SHAP) oferecem atribuição local. O protótipo HuntGPT integra um detector de anomalias por ML a um LLM que entrega justificativas textuais – referência explícita do projeto. Estudos recentes exploram LLMs para detecção de intrusão explicável e explicabilidade em SDN . A calibração e a confiança das justificativas são temas ativos .

2.7 Geração de Cenários Anômalos e Datasets Públicos

A literatura estabelece UNSW-NB15 e CSE-CIC-IDS2018 como benchmarks modernos, superando os obsoletos KDD99/NSL-KDD . A geração dessas bases segue perfis comportamentais e emulação (Mininet, GNS3, PNET-Lab) . Datasets SDN específicos (InSDN , SNT, DDoS2019) e técnicas de *data augmentation* (GAN/VAE/SMOTE) endereçam o desbalanceamento de classes . A conversão de atributos numéricos em representações textuais – formalizada por AnoLLM e revisada em surveys de LLMs em dados tabulares – abre caminho para detectores baseados em LLMs, eixo conectado diretamente à inferência do sistema analisado .

3 O Sistema Implementado: NOC Lite

O *NOC Lite* é um sistema de monitoramento de disponibilidade e performance de *hosts* genéricos, estruturado como um monolito modular em FastAPI com persistência em SQLite e um *front-end* estático. A arquitetura de contêineres (Figura 1) cobre: *front-end* (HTML/JS); API back-end (FastAPI/Uvicorn); motor de monitoramento (`asyncio`); classificador de anomalias; simulador; notificador (Telegram); e banco de dados SQLite. Atenção especial: o classificador de anomalias **não participa do laço de monitoramento** – é acionado sob demanda via `GET /api/anomalies/classify`, jamais pelo *MonitorEngine*.

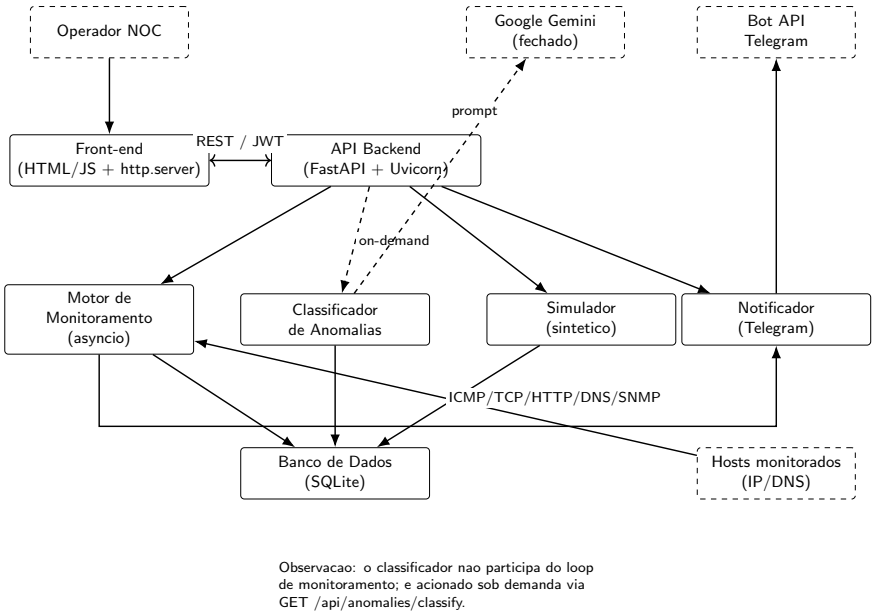


Figure 1: Arquitetura de contêineres do NOC Lite (C4, nível contêiner). Fonte: elaborada a partir de `arquitetura_sistema.md` (Dan).

3.1 Pipeline de Classificação

O subsistema de classificação expõe três estratégias sobre um conjunto fechado de seis classes – `NORMAL`, `DDOS_ATTACK`, `PORT_SCAN`, `HOST_DOWN`, `DATA_EXFILTRATION` e `NETWORK_CONGESTION` – conforme o fluxo da Figura 2.

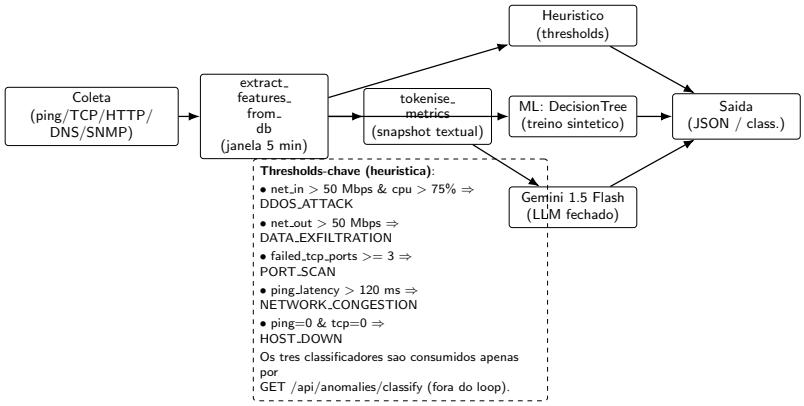


Figure 2: Pipeline de classificação de anomalias do NOC Lite: extração de features (janela de 5 min), três classificadores paralelos e tokenização para o LLM. Fonte: `notas_coder.md` (John).

1. **Heurístico (baseline 1)** – `classify_heuristic`: regras de limiar estático. Ex.: `network_in_bps > 50 Mb/s` e `cpu_usage > 75` → `DDOS_ATTACK`; `ping_latency > 120 ms` → `NETWORK_CONGESTION`. Produz confiança fixa e explicação textual.

2. **Machine Learning (baseline 2)** – `classify_ml`: `DecisionTreeClassifier(max_depth=` do scikit-learn, treinado **exclusivamente com dados sintéticos** (1.200 amostras, 200 por classe). Sem PEFT, sem LLM.

3. **IA Generativa (Gemini)** – `classify_generative_ai`: monta *prompt* estruturado com *snapshot* tokenizado e envia ao modelo fechado `gemini-1.5-flash`, retornando JSON com `classification`, `confidence` e `explanation`. Possui *fallback* para a heurística.

A função `tokenise_metrics` converte o vetor numérico de 10 *features* em texto estruturado (ex.: `PingSuccessRate: 0.95 | AvgPingLatency: 12.3 ms | CPUUsage: 34.1%`), espelhando a recomendação do projeto de converter atributos numéricos em representações textuais . Esse texto é a ponte que permite ao LLM "ler" os limiares de rede em linguagem natural.

3.2 Simulador

O `anomaly_simulator.py` gera cenários anômalos sintéticos (`generate_simulated_metrics`) para as seis classes via `random.uniform`, e injeta esses vetores diretamente no banco (`run_simulated_check_cycle`), podendo popular histórico retroativo. O agendamento em tempo real usa estado em memória. Trata-se de dados 100% sintéticos, sem dependência de datasets públicos.

4 Mapeamento Projeto × Sistema e Gaps

A Tabela 1 sintetiza a correspondência entre os objetivos/componentes do projeto norteador Rodrigues, João Pedro Santos, 2026 e o que o NOC Lite efetivamente entrega, com o respectivo status de alinhamento. A Figura 3 ilustra essa relação.

Table 1: Mapeamento Projeto de Pesquisa × NOC Lite.

#	**Objetivo/Componente do Projeto**	**Entrega do NOC Lite**	**Status**
1	LLM *open source* (Llama/Falcon) com fine-tuning	Gemini 1.5 Flash (fechado); Árvore de Decisão	Divergente
2	Fine-tuning PEFT (LoRA/QLoRA)	Inexistente; ML é árvore treinada do zero	Ausente
3	Ambiente SDN virtualizado (Mininet/OVS)	Hosts IP genéricos; sondas ICMP/TCP/HTTP/DNS/SNMP	Ausente
4	Mitigação via reconfiguração VNT/roteamento (ciclo fechado)	Apenas detecção + alerta Telegram; sem ação corretiva	Ausente
5	Anomalias de performance (congestionamento, falha de enlace)	Mistura anomalias de segurança/operacionais com congest. genérico	Parcial
6	Datasets públicos (UNSW-NB15, CIC-IDS2018, Synthetic SDN)	Dados 100% sintéticos (random.uniform)	Divergente
7	Baselines de comparação (heurística / ML)	Heurística + DecisionTree	Convergente
8	Tokenização de métricas em texto estruturado	`tokenise_metrics`	Convergente
9	Justificativa textual (XAI)	`explanation` (com modelo fechado)	Convergente
10	Avaliação de tempo de resposta por classificador	`latency_ms` medido por classificador	Convergente
11	Métricas resumidas (throughput, latência, jitter, perda)	SLA/jitter/tendência/health-score + SNMP	Convergente
12	Ciclo fechado coleta→classificação→mitigação	Loop aberto: coleta→severidade→alerta	Aberto

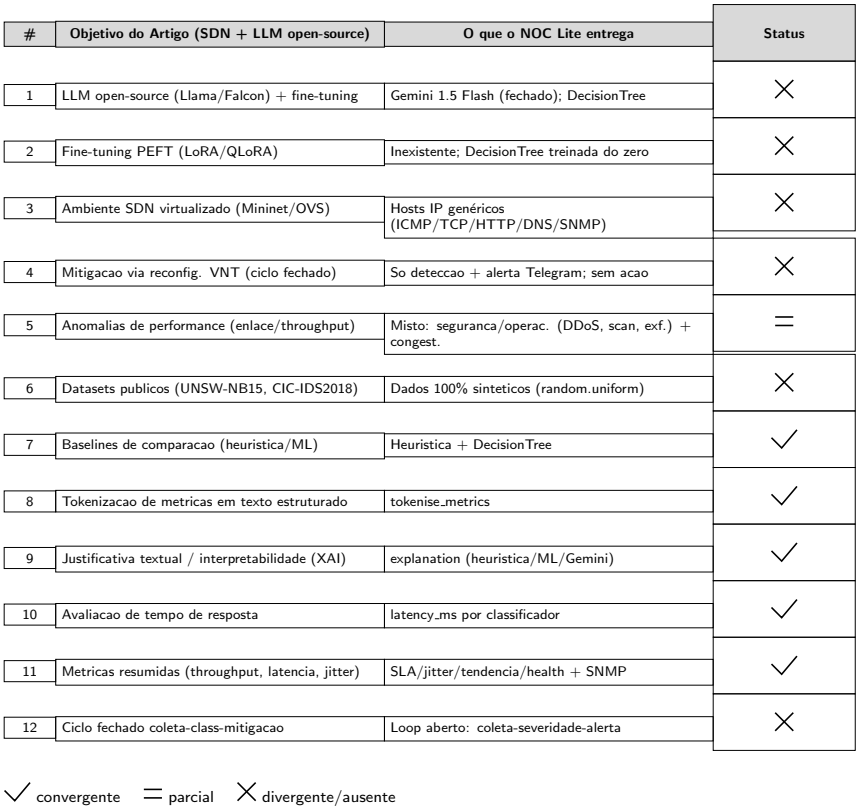


Figure 3: Mapeamento visual entre os objetivos do artigo norteador e o sistema NOC Lite. Fonte: elaborada por Chris.

4.1 Taxonomia de Gaps

A análise arquitetural identifica sete gaps, seis de severidade crítica/maior (Figura 4). Cada gap é sustentado por evidência de código.

Table 2: Taxonomia de gaps (NOC Lite × Projeto).

ID	Gap	Evidência no código / Descrição	Severidade
GAP-1	SDN vs. hosts genéricos	Busca por `sdn|mininet|vnt|controller` → 0 ocorrências; `Host.address`arbítrio	Crítico
GAP-2	Gemini fechado vs. LLM *open source*	`genai.GenerativeModel("gemini-1.5-flash")`; depende de `GEMINI_API_KEY`	Crítico
GAP-3	Ausência de LoRA/QLoRA	Busca por `lora|qlora|peft|fine.?tun` → 0; único modelo treinável é DecisionTree	Crítico

ID	Gap	Evidência no código / Descrição	Severidade
GAP-4	Ausência de mitigação / loop aberto	`scheduler.py` não referencia nenhum `classify_*`; inferência só em `/api/anomalies/classify`	Crítico
GAP-5	Dados sintéticos vs. datasets públicos	`random.uniform` em `anomaly_simulator.py`; busca `unsw|cic-ids` $\rightarrow 0$	Maior
GAP-6	Performance vs. segurança/operacionais	Classes majoritariamente de segurança; congest. por limiar genérico de latência de ping	Maior
GAP-7	Interpretabilidade com modelo fechado	`explanation` provém do Gemini; sem rastreabilidade de pesos nem reprodutibilidade local	Menor

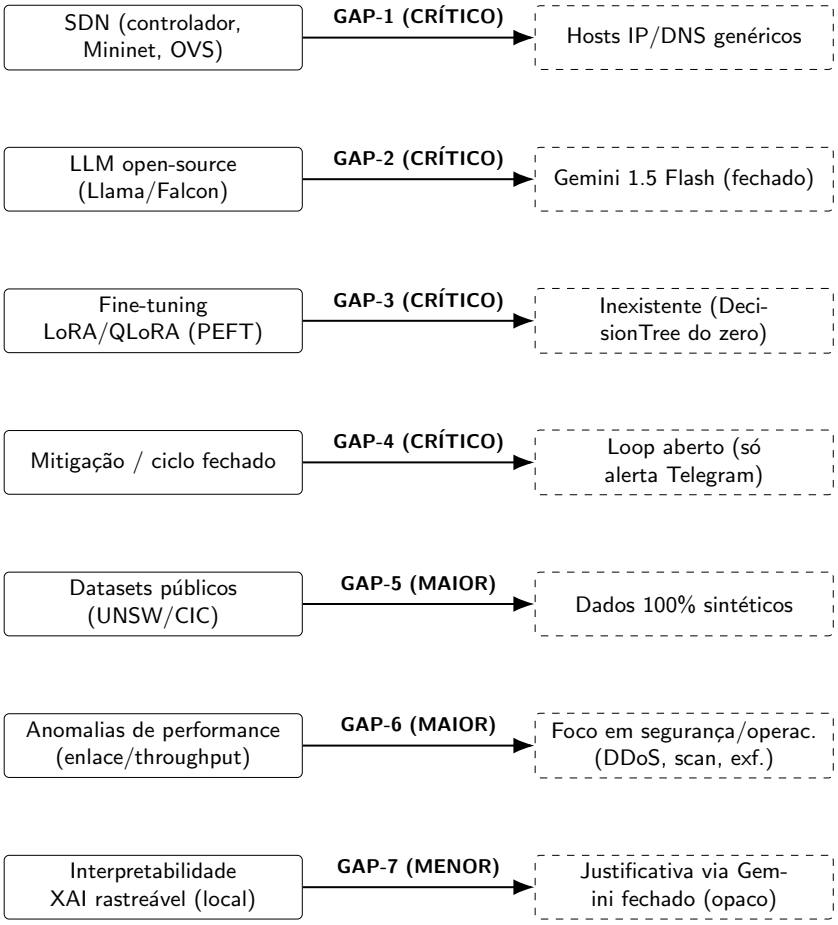


Figure 4: Taxonomia de gaps estruturais entre o projeto norteador e o NOC Lite. Fonte: elaborada por Chris.

GAP-1 (SDN vs. hosts). O projeto fundamenta toda a proposta no paradigma SDN; o NOC Lite monitora hosts IP/DNS arbitrários, sem controlador, topologia virtualizada ou planos separados . **GAP-2 (modelo fechado).** O projeto exige LLMs *open source* e classifica explicitamente o Gemini como modelo fechado Rodrigues, João Pedro Santos, 2026; o sistema o usa em regime *zero-shot* . **GAP-3 (sem LoRA/QLoRA).** A seção de PEFT do projeto não tem correspondente: o único modelo treinável é uma árvore de decisão do zero . **GAP-4 (loop aberto).** A classificação por IA não está integrada ao laço de detecção; o ciclo observa e alerta, sem atuação autônoma . **GAP-5 (dados sintéticos).** O treino e o *few-shot* repousam no simulador; ausente a validação cruzada com UNSW-NB15, . **GAP-6 (escopo).** O foco do projeto é performance (congestionamento, falha de

enlace, degradação de desempenho); o sistema privilegia classes de segurança . **GAP-7 (XAI com fechado).** A justificativa provém de modelo opaco, fragilizando a promessa de XAI do projeto .

5 Discussão

5.1 Convergências preservadas

Apesar dos desalinhamentos, o NOC Lite honra parcela da intenção do projeto:

1. **Baselines de comparação** – implementa exatamente heurística e árvore de decisão, permitindo comparação direta lado a lado .
2. **Tokenização de métricas** – `tokenise_metrics` converte o vetor numérico em representação semiestruturada, alinhada à recomendação de conversão textual .
3. **Justificativa textual / XAI** – todos os classificadores retornam `explanation`, atendendo ao objetivo qualitativo de interpretabilidade .
4. **Métricas de tempo de resposta** – o endpoint mede `latency_ms` de cada classificador, entregando a métrica de desempenho exigida .
5. **Métricas resumidas de rede** – SLA, jitter, tendência e health-score capturam latência/perda/jitter, coincidentes com as métricas de performance do projeto .

5.2 Limitações e ameaças à validade

Viés de dados sintéticos. O classificador de ML é treinado 100% com o próprio simulador, que compartilha os mesmos limiares da heurística; a árvore aprende essencialmente a "copiar" a heurística em forma de árvore, com alto desempenho no sintético e provável colapso em produção . **Confiança não calibrada.** A confiança do Gemini é autorreportada e a do ML é probabilidade de folha não calibrada ; a comparação entre classificadores é, portanto, metodologicamente assimétrica. **Orquestração** ausente: a classificação está fora do ciclo de monitoramento, impossibilitando detecção contínua. **Validade externa**: a ausência de datasets públicos impede a comparação com o estado da arte .

Ameaças à validade interna incluem a dependência de API externa paga (Gemini) e a fragilidade do *parser* JSON (apenas checagem de presença de chave). **Ameaças à validade de construção**: os limiares de 50 Mb/s e 120 ms são fixos e universais, sem *baseline* por host/link, gerando falsos positivos em enlaces de capacidades distintas .

6 Diretrizes de Arquitetura para Alinhamento

Para reduzir a distância entre o NOC Lite e o projeto, propõe-se uma evolução arquitetural incremental, respeitando o que já existe e fechando os sete gaps. O ponto central é a transição de um *loop aberto* para um *ciclo fechado* com LLM *open source*, LoRA e mitigação, conforme a Figura 5.

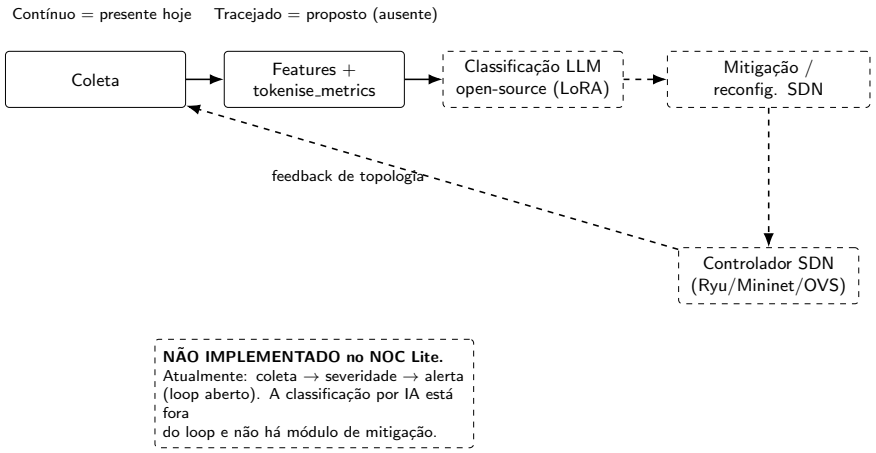


Figure 5: Arquitetura proposta de ciclo fechado: coleta (SDN + hosts) → tokenização → classificação (LLM *open source* + LoRA) → mitigação (módulo de ação) → reconfiguração via controlador. Fonte: elaborada por Chris.

1. **Substituição do modelo fechado por LLM local (fecha GAP-2, GAP-3).** Introduzir contêiner de inferência local (vLLM/llama.cpp/Ollama) servindo Llama 3 (7–13B) ou Falcon via endpoint compatível com OpenAI; substituir `gemini-1.5-flash` por cliente HTTP local, mantendo o *fallback* heurístico. Aplicar LoRA/QLoRA (rank 16–32, alpha 32) sobre o modelo base, reutilizando os *prompts* de `tokenise_metrics` .

2. **Pipeline de dados com datasets públicos (fecha GAP-5).** Criar módulo `data_ingest` que baixa/normaliza UNSW-NB15, CSE-CIC-IDS2018 e Synthetic SDN para o *schema* de *features*; treinar LoRA e

a árvore com dados reais, preservando o simulador para demonstração .

3. **Ambiente SDN e fechamento do ciclo (fecha GAP-1, GAP-4).** Adicionar contêiner Mininet + controlador Ryu que emule a topologia e exponha telemetria de enlace/fluxo; generalizar `Host`/`CheckResult` para telemetria de fluxo SDN; criar `mitigation_engine` que mapeia `classification` → ação corretiva (re-rota, QoS, *drop* de fluxo) via NorthBound API do controlador; integrar o classificador dentro do `MonitorEngine`, fechando o ciclo .

4. **Realinhamento do catálogo de anomalias (fecha GAP-6).** Separar claramente performance SDN (congestionamento de enlace, falha de enlace, degradação de throughput/jitter) de segurança/operacional (DDoS, port scan, exfiltração, host down), priorizando a primeira família .

5. **Preservação dos pontos fortes.** Manter `tokenise_metrics`, o par baseline heurístico + ML, a medição de `latency_ms` e o formato de `explanation` como base do novo pipeline .

6. **Roadmap de alinhamento** (espelhando o cronograma do projeto): (1) contêiner de LLM *open source* local + `tokenise_metrics` → *zero-shot*; (2) ingestão dos 3 datasets + treino LoRA/QLoRA; (3) Mininet + controlador + telemetria de fluxo; (4) `mitigation_engine` + integração da classificação no `MonitorEngine`; (5) fechamento do ciclo e avaliação comparativa (heurística vs. ML vs. LLM *open source* com/sem LoRA), reutilizando `latency_ms` e acrescentando acurácia/consistência.

7 Conclusão

O presente artigo correlacionou o projeto de pesquisa que propõe detecção e mitigação de anomalias em SDN com LLMs *open source* ajustados por PEFT/LoRA Rodrigues, João Pedro Santos, 2026 com o sistema efetivamente implementado, o NOC Lite. Evidenciou-se que o sistema realiza com sucesso a parcela de *baselines* e de representação textual do projeto – heurística, árvore de decisão, tokenização de métricas, justificativa textual e medição de latência – mas diverge estruturalmente nos eixos centrais da proposta. Especificamente, o NOC Lite (i) monitora hosts genéricos e não SDN; (ii) emprega o modelo fechado Gemini em vez de LLM *open source*;

(iii) não aplica LoRA/QLoRA; (iv) não realiza mitigação nem opera em ciclo fechado; e (v) depende exclusivamente de dados sintéticos, sem validação cruzada com datasets públicos.

Tais gaps não são ajustes pontuais: exigem evolução arquitetural substantiva, sintetizada nas diretrizes de um ciclo fechado com LLM local, LoRA e módulo de mitigação. As convergências identificadas funcionam como alicerce seguro sobre o qual construir essa evolução, uma vez que o `tokenise_metrics`, os baselines e a medição de latência já cumprem objetivos específicos do projeto. Como trabalho futuro, recomenda-se a implementação do `mitigation_engine` e a condução do experimento comparativo head-to-head entre LLM *open source* ajustado por QLoRA e LLM fechado *zero-shot* sobre o mesmo conjunto de métricas de rede – lacuna exatamente apontada pela literatura .

Referências

References

[1] [Referência não recuperada: rRODRIGUES]

[2] [Referência não recuperada: rA39]

[3] [Referência não recuperada: rA512]

[4] [Referência não recuperada: rA31]

[5] [Referência não recuperada: rA321]

[6] [Referência não recuperada: rA19]

[7] [Referência não recuperada: rA28]

[8] [Referência não recuperada: rA212]

[9] [Referência não recuperada: rA11]

[10] [Referência não recuperada: rA12]

[11] [Referência não recuperada: rA116]

[12] [Referência não recuperada: rA114]

[13] [Referência não recuperada: rA115]

[14] [Referência não recuperada: rA122]

[15] [Referência não recuperada: rA123]

[16] [Referência não recuperada: rA124]

[17] [Referência não recuperada: rA14]

[18] [Referência não recuperada: rA15]

[19] [Referência não recuperada: rA110]

[20] [Referência não recuperada: rA127]

[21] [Referência não recuperada: rA128]

[22] [Referência não recuperada: rA129]

[23] [Referência não recuperada: rA130]

[24] [Referência não recuperada: rA131]

[25] [Referência não recuperada: rA132]

[26] [Referência não recuperada: rA133]

[27] [Referência não recuperada: rA134]

[28] [Referência não recuperada: rA135]

[29] [Referência não recuperada: rA126]

[30] [Referência não recuperada: rA22]

[31] [Referência não recuperada: rA21]

[32] [Referência não recuperada: rA25]

[33] [Referência não recuperada: rA27]

[34] [Referência não recuperada: rA213]

[35] [Referência não recuperada: rA210]

[36] [Referência não recuperada: rA217]

[37] [Referência não recuperada: rA231]

[38] [Referência não recuperada: rA29]

[39] [Referência não recuperada: rA222]

[40] [Referência não recuperada: rA224]

[41] [Referência não recuperada: rA225]

[42] [Referência não recuperada: rA227]

[43] [Referência não recuperada: rA229]

[44] [Referência não recuperada: rA226]

[45] [Referência não recuperada: rA232]

[46] [Referência não recuperada: rA32]

[47] [Referência não recuperada: rA33]

[48] [Referência não recuperada: rA34]

[49] [Referência não recuperada: rA35]

[50] [Referência não recuperada: rA36]

[51] [Referência não recuperada: rA37]

[52] [Referência não recuperada: rA310]

[53] [Referência não recuperada: rA311]

[54] [Referência não recuperada: rA312]

[55] [Referência não recuperada: rA313]

[56] [Referência não recuperada: rA314]

[57] [Referência não recuperada: rA315]

[58] [Referência não recuperada: rA316]

[59] [Referência não recuperada: rA317]

[60] [Referência não recuperada: rA41]

[61] [Referência não recuperada: rA319]

[62] [Referência não recuperada: rA320]

[63] [Referência não recuperada: rA325]

[64] [Referência não recuperada: rA327]

[65] [Referência não recuperada: rA324]

[66] [Referência não recuperada: rA332]

[67] [Referência não recuperada: rA333]

[68] [Referência não recuperada: rA338]

[69] [Referência não recuperada: rA334]

[70] [Referência não recuperada: rA335]

[71] [Referência não recuperada: rA336]

[72] [Referência não recuperada: rA337]

[73] [Referência não recuperada: rA42]

[74] [Referência não recuperada: rA43]

[75] [Referência não recuperada: rA44]

[76] [Referência não recuperada: rA45]

[77] [Referência não recuperada: rA49]

[78] [Referência não recuperada: rA415]

[79] [Referência não recuperada: rA411]

[80] [Referência não recuperada: rA412]

[81] [Referência não recuperada: rA425]

[82] [Referência não recuperada: rA426]

[83] [Referência não recuperada: rA427]

[84] [Referência não recuperada: rA422]

[85] [Referência não recuperada: rA424]

[86] [Referência não recuperada: rA52]

[87] [Referência não recuperada: rA531]

[88] [Referência não recuperada: rA517]

[89] [Referência não recuperada: rA51]

[90] [Referência não recuperada: rA53]

[91] [Referência não recuperada: rA54]

[92] [Referência não recuperada: rA511]

[93] [Referência não recuperada: rA520]

[94] [Referência não recuperada: rA521]

[95] [Referência não recuperada: rA522]

[96] [Referência não recuperada: rA532]

[97] [Referência não recuperada: rA533]

[98] [Referência não recuperada: rA534]

[99] [Referência não recuperada: rA61]

[100] [Referência não recuperada: rA62]

[101] [Referência não recuperada: rA63]

[102] [Referência não recuperada: rA64]

[103] [Referência não recuperada: rA65]

[104] [Referência não recuperada: rA66]

[105] [Referência não recuperada: rA69]

[106] [Referência não recuperada: rA629]

[107] [Referência não recuperada: rA610]

[108] [Referência não recuperada: rA614]

[109] [Referência não recuperada: rA615]

[110] [Referência não recuperada: rA623]

[111] [Referência não recuperada: rA616]

[112] [Referência não recuperada: rA617]

[113] [Referência não recuperada: rA618]

[114] [Referência não recuperada: rA630]

[115] [Referência não recuperada: rA431]

[116] [Referência não recuperada: rA432]

[117] [Referência não recuperada: rA537]

[118] [Referência não recuperada: rA414]

References

[1] McKEOWN et al, 2008. A network in a laptop: rapid prototyping for software-defined networks.

[2] XIA et al, 2015. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models.

[3] MEDVED et al, 2014. MEDVED, J.; VARGA, R.; TKACIK, A.; GRAY, K. OpenDaylight: Towards a Model-Driven SDN Controller Architecture. ACM SIGCOMM HotSDN '14, p. 1–6, 2014..

[4] BERDE et al, 2014. BERDE, P.; GEROLA, M.; HART, J.; HIGUCHI, Y.; KOBAYASHI, M.; KOIDE, T.; et al. ONOS: Towards an Open, Distributed SDN OS. ACM SIGCOMM HotSDN '14, p. 1–6, 2014..

[5] NTT Laboratories. Ryu SDN Framework - Open-source SDN Platform Software. NTT Technical Review, 2014. NTT Laboratories. Ryu SDN Framework — Open-source SDN Platform Software. NTT Technical Review, v. 12, n. 8, 2014..

[6] GUDE et al, 2008. GUDE, N.; KOPONEN, T.; PETTIT, J.; PFAFF, B.; MCKEOWN, N.; SHENKER, S.; CASADO, M. NOX: Towards an Operating System for Networks. ACM SIGCOMM Computer Communication Review, v. 38, n. 3, p. 105–110, 2008..

[7] PORRAS et al, 2012. PORRAS, P.; SHIN, S.; YEGNESWARAN, V.; FONG, M.; TYSON, M.; GU, G. A Security Enforcement Kernel for OpenFlow Networks. ISOC NDSS '12, 2012..

[8] LI et al, 2016. Referencia: LI et al. (2016).

[9] BHUIYAN et al, 2023. BHUIYAN, Z. A.; ISLAM, S.; ISLAM, M. M.; ULLAH, A. A.; NAZ, F.; RAHMAN, M. S. On the (in)Security of the Control Plane of SDN Architecture: A Survey. IEEE Access, v. 11, p. 91550–91582, 2023..

[10] LATIF et al, 2022. LATIF, Z.; SHARIF, K.; LI, F.; KARIM, M. M.; BELGHITI, M. A.; SANGEEN, A. A Machine Learning-Based Anomaly Prediction Service for Software-Defined Networks. Sensors, v. 22, n. 21, artigo 8434, 2022..

[11] CHIOSI et al, 2012. CHIOSI, M.; CLARKE, D.; HAMPSON, P.; et al.

[12] ETSI NFV ISG. GS NFV 002 V1.1.1: Network Functions Virtualisation (NFV); Architectural Framework. ETSI et al, 2013. ETSI, arquitetura, MANO, orquestração, VNF placement. E5. Intent-Based Networking (IBN), reconfiguração proativa de topologia virtual (VNT) e roteamento em ciclo fechado (closed-loop.

[13] ETSI NFV ISG. GS NFV-MAN 001 V1.1.1: Network Functions Virtualisation (NFV); Management and Orchestration. ETSI et al, 2014. ETSI, arquitetura, MANO, orquestração, VNF placement. E5. Intent-Based Networking (IBN), reconfiguração proativa de topologia virtual (VNT) e roteamento em ciclo fechado (closed-loop.

[14] MIJUMBI et al, 2015. MIJUMBI, R.; SERRAT, J.; GORRICHO, J.-L.; BOUTEN, N.; DE TURCK, F.; BOUTABA, R. Network Function Virtualization: State-of-the-Art and Research Challenges. IEEE Communications Magazine, v. 53, n. 2, p. 216–228, 2015..

[15] MIJUMBI et al, 2016. MIJUMBI, R.; SERRAT, J.; GORRICHO, J.-L.; BOUTEN, N.; DE TURCK, F.; BOUTABA, R. Network Function Virtualization: State-of-the-Art and Research Challenges. IEEE Communications Magazine, v. 53, n. 2, p. 216–228, 2015..

[16] LAGHRISSI et al, 2019. LAGHRISSI, A.; TALEB, T. A Survey on the Placement of Virtual Resources and Virtual Network Functions. IEEE Communications Surveys Tutorials, v. 21, n. 2, p. 1409–1434, 2019..

[17] LEIVADEAS et al, 2022. LEIVADEAS, A.; FALKNER, M. A Survey on Intent-Based Networking. IEEE Communications Surveys Tutorials, v. 25, n. 1, p. 625–655, 1º trim. 2023.

[18] MORALES et al, 2017. MORALES, F.; RUIZ, M.; CONTRERAS, L. M.; FERRARIS, G.; STAVDAS, A.; CUGINI, F.; VELASCO, L. Virtual Network Topology Adaptability Based on Data Analytics for Traffic Prediction. IEEE/OSA Journal of Optical Communications and Networking, v. 9, n. 1, p. A35–A45, 2017..

[19] VELASCO et al, 2022. roteamento em ciclo fechado.

[20] LANTZ et al, 2010. A network in a laptop: rapid prototyping for software-defined networks.

[21] PFAFF et al, 2015. PFAFF, B.; MCKEOWN, N.; SHENKER, S.; CASADO, M. NOX: Towards an Operating System for Networks. ACM SIGCOMM Computer Communication Review, v. 38, n. 3, p. 105–110, 2008..

[22] KREUTZ et al, 2015. KREUTZ, D.; RAMOS, F. M. V.; VERISSIMO, P. E.; ROTHENBERG, C. E.; AZODOLMOLKY, S.; UHLIG, S. Software-Defined Networking: A Comprehensive Survey. Proceedings of the IEEE, v. 103, n. 1, p. 14–76, 2015..

[23] BRUTLAG, 2000. [Acesso via assinatura].

[24] BHUYAN et al, 2014. BHUYAN, M. H.; BHATTACHARYYA, D. K.; KALITA, J. K. Network Anomaly Detection: Methods, Systems and Tools. IEEE Communications Surveys Tutorials, v. 16, n. 1, p. 303–336, 2014. DOI: https://doi.org/10.1109/SURV.2013.052213.00046 URL: https://ieeexplore.ieee.org/iel7/9739/6734841/06524462.pdf.

[25] BUCZAK et al, 2016. BUCZAK, A. L.; GÜVEN, E. A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection. IEEE Communications Surveys Tutorials, v. 18, n. 2, p. 1153–1176, 2016. DOI: https://doi.org/10.1109/COMST.2015.2494502 (>5300 citações) URL: https://ieeexplore.ieee.org/document/7307098/.

[26] CORTES et al, 1995. CORTES, C.; VAPNIK, V. Support-Vector Networks. Machine Learning, v. 20, n. 3, p. 273–297, 1995. DOI: https://doi.org/10.1007/BF00994018 URL: https://link.springer.com/article/10.1007/BF00994018.

[27] CARUANA et al, 2006. CARUANA, R.; NICULESCU-MIZIL, A. An Empirical Comparison of Supervised Learning Algorithms. In: Proc. of the 23rd International Conference on Machine Learning (ICML 2006), p. 161–168, 2006. DOI: https://doi.org/10.1145/1143844.1143865 URL: https://www.cs.cornell.edu/ caruana/ctp/ct.papers/caruana.icml06.pdf.

[28] ROBERTS, 1959. ROBERTS, S. W. Control Chart Tests Based on Geometric Moving Averages. Technometrics, v. 1, n. 3, p. 239–250, 1959..

[29] HODO et al, 2017. HODO, E.; BELLEKENS, X.; HAMILTON, A.; DUBOULIL, C.; PHAM, Q. N. Threat Analysis of IoT Networks Using Artificial Neural Network Intrusion Detection System. In: Int. Symp. on Networks, Computers and Communications (ISNCC), IEEE, 2017. DOI: https://doi.org/10.1109/ISNCC.2017.8005728 URL: https://ieeexplore.ieee.org/document/8005728/.

[30] ALDUAILIJ et al, 2022. [Acesso via assinatura].

[31] NEGANDHI et al, 2016. NEGANDHI, P.; TRIVEDI, Y. Intrusion Detection System Using Random Forest on the NSL-KDD Dataset. In: Proc. of Int. Conf. on Computing, Analytics and Security Trends

(CAST), 2016. URL:
https://www.researchgate.net/publication/335718695$_{I}ntrusion_{D}etection_{S}ystem_{U}sing_{R}and$
$KDD_{D}ataset$.

[31] WILLEMS et al, 2023. [Acesso via assinatura].

[32] SHEHAB et al, 2024. SHEHAB, R. et al. Improving Port Scan Cybersecurity Risks Detection using Feature Selection and Machine Learning. JATIT, v. 102, n. 16, 2024. URL: https://www.jatit.org/volumes/Vol102No16/9Vol102No16.pdf.

[33] STANIFORD-CHEN et al, 1996. STANIFORD-CHEN, S.; CHEUNG, S.; CRAWFORD, R.; DILGER, M.; FRANK, J.; HOAGLAND, J.; LEVITT, K.; WEINTRAUB, C.; YIP, D.; ZERKLE, D. GrIDS — A Graph-Based Intrusion Detection System for Large Networks. In: Proc. of the 19th National Information Systems Security Conference (NISSC), 1996. URL: https://seclab.cs.ucdavis.edu/papers/nissc96.pdf.

[34] CANNADY, 1998. CANNADY, J. D. Artificial Neural Networks for Misuse Detection. In: Proc. of the 1998 National Information Systems Security Conference (NISSC), 1998. URL: https://csrc.nist.gov/nissc/1998/proceedings/paperF13.pdf.

[35] LAKHINA et al, 2004. LAKHINA, A.; CROVELLA, M.; DIOT, C. Diagnosing Network-Wide Traffic Anomalies. In: Proc. of ACM SIGCOMM 2004, p. 219–230, 2004. DOI: https://doi.org/10.1145/1030194.1015492 URL: https://dl.acm.org/doi/10.1145/1030194.1015492.

[36] MOAYEDI et al, 2008. MOAYEDI, H. Z.; AMINI, M. ARIMA Model for Network Traffic Prediction and Anomaly Detection. In: Proc. of the 4th International Conference on Information Technology (ICIT 2008), IEEE, 2008. DOI: https://doi.org/10.1109/ICIT.2008.22 (via IEEE Xplore) URL: https://ieeexplore.ieee.org/document/4631947/.

[37] FONDO-FERREIRO et al, 2026. FONDO-FERREIRO, P. et al. Real-time SARIMA-based anomaly detection in operator networks. Computer Networks (Elsevier), 2026. DOI: [NÃO VERIFICADO — usar URL abaixo; artigo de 2026 ainda em indexação] URL: https://www.sciencedirect.com/science/article/pii/S1389128626000824.

[38] CHANDOLA et al, 2009. CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly Detection: A Survey. ACM Computing Surveys,

v. 41, n. 3, p. 1–58, 2009. DOI: https://doi.org/10.1145/1541880.1541882 URL: https://dl.acm.org/doi/10.1145/1541880.1541882.

[39] AHMED et al, 2016. A Survey on Large Language Models for Communication, Network, and Service Management: Application Insights, Challenges, and Future Directions.

[40] LIU et al, 2025. On IoT intrusion detection based on data augmentation for enhancing learning on unbalanced samples.

[41] TOUVRON et al, 2023. TOUVRON, H.; LAVRIL, T.; IZACARD, G.; MARTINET, X.; LACHAUX, M.-A.; LACROIX, T. et al. LLaMA: Open and Efficient Foundation Language Models. 2023. arXiv:2302.13971. DOI: https://doi.org/10.48550/arXiv.2302.13971 URL: https://arxiv.org/abs/2302.13971.

[42] TOUVRON et al, 2023. TOUVRON, H.; LAVRIL, T.; IZACARD, G.; MARTINET, X.; LACHAUX, M.-A.; LACROIX, T. et al. LLaMA: Open and Efficient Foundation Language Models. 2023. arXiv:2302.13971. DOI: https://doi.org/10.48550/arXiv.2302.13971 URL: https://arxiv.org/abs/2302.13971.

[43] JIANG et al, 2023. JIANG, A. Q.; SABLAYROLLES, A.; MENSCH, A.; BAMFORD, C.; CHAPLOT, D. S. et al. Mistral 7B. 2023. arXiv:2310.06825. DOI: https://doi.org/10.48550/arXiv.2310.06825 URL: https://arxiv.org/abs/2310.06825.

[44] ALMAZROUEI et al, 2023. The Falcon Series of Open Language Models.

[45] BAI et al, 2023. Qwen Technical Report.

[46] YANG et al, 2024. YANG, Z.; TANG, J. P-Tuning v2: Prompt Tuning Can Be Comparable to Fine-tuning Universally Across Scales and Tasks. ACL, 2022. arXiv:2110.07602. DOI: https://doi.org/10.48550/arXiv.2110.07602 URL: https://arxiv.org/abs/2110.07602.

[47] BIGSCIENCE WORKSHOP et al, 2022. BLOOM: A 176B-Parameter Open-Access Multilingual Language Model.

[48] GEMMA TEAM (Google DeepMind). Gemma: Open Models Based on Gemini Research and Technology. arXiv preprint arXiv:2403.08295,

2024. Gemma: Open Models Based on Gemini Research and Technology.

[49] VASWANI et al, 2017. Attention Is All You Need.

[50] LIU et al, 2024. On IoT intrusion detection based on data augmentation for enhancing learning on unbalanced samples.

[51] OUYANG et al, 2022. Training Language Models to Follow Instructions with Human Feedback (InstructGPT).

[52] WEI et al, 2022. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models.

[53] HOSSAIN et al, 2025. NetIntent: Leveraging Large Language Models for End-to-End Intent-Based SDN Automation.

[54] SDN-Xplain: LLM-Driven Anomaly Detection and Human-Interpretable Explanation in SDN. SKKU IoT Lab / KICS Winter 2026 (preprint), 2026. Referencia: SDN-Xplain: LLM-Driven Anomaly Detection and Human-Interpretable Explanation in SDN. SKKU IoT Lab / KICS Winter 2026 (preprint). (2026).

[55] Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN. arXiv/ResearchGate preprint, 2025. Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN." arXiv:2510.23313 (preprint), 2025. [título/autoria consolidados no preprint] URL: https://arxiv.org/html/2510.23313v1.

[56] BOATENG et al, 2024. A Survey on Large Language Models for Communication, Network, and Service Management: Application Insights, Challenges, and Future Directions.

[57] ADANZA et al, 2025. Leveraging Generative AI for Intent-Based Networking.

[58] Towards Intent-Based Network Management: Large Language Models for Intent Extraction in 5G Core Networks. IEEE / GenAI Net research library, 2024. Towards Explainable Network Intrusion Detection using Large Language Models." arXiv:2408.04342, 2024. URL: https://arxiv.org/abs/2408.04342.

[59] Exploring LLM-Based Agents for Root Cause Analysis. ACM SIGMETRICS / arXiv:2403.04123, 2024. Exploring LLM-Based

Agents for Root Cause Analysis". ACM SIGMETRICS / arXiv:2403.04123, 2024..

[60] Empowering AIOps: Leveraging Large Language Models for IT Operations Management. arXiv:2501.12461, 2025. Empowering AIOps: Leveraging Large Language Models for IT Operations Management". arXiv:2501.12461, 2025..

[61] WANG et al, 2025. On the Calibration of Large Language Models and Alignment.

[62] LLM-Driven Multi-Agent Framework for Autonomous Network Slice Management. IEEE, 2026. Large Language Models Meet Next-Generation Networking Technologies: A Review.

[63] CHEN et al, 2024. Explainable Intrusion Detection Systems (X-IDS): A Survey of Current Methods, Challenges, and Opportunities.

[64] HANG et al, 2024. Large Language Models Meet Next-Generation Networking Technologies: A Review.

[65] HUANG et al, 2024. Explainable and Interpretable Multimodal Large Language Models: A Comprehensive Survey.

[66] HONG et al, 2025. A Comprehensive Survey on LLM-Based Network Management and Orchestration.

[67] ZHANG et al, 2025. When LLMs Meet Cybersecurity: A Systematic Literature Review.

[68] TANG et al, 2024. TANG, J. P-Tuning v2: Prompt Tuning Can Be Comparable to Fine-tuning Universally Across Scales and Tasks. ACL, 2022. arXiv:2110.07602. DOI: https://doi.org/10.48550/arXiv.2110.07602 URL: https://arxiv.org/abs/2110.07602.

[69] HU et al, 2021. Referencia: HU et al. (2021).

[70] HU et al, 2023. Referencia: HU et al. (2023).

[71] ZHANG et al, 2024. When LLMs Meet Cybersecurity: A Systematic Literature Review.

[72] DING et al, 2022. AnoLLM: Large Language Models for Tabular Anomaly Detection.

[73] HAN et al, 2024. HAN, J.; LIU, C.; GAO, P.; ZHOU, A.; HU, X.; YAN, S.; LU, P.; LI, H.; QIAO, Y. LLaMA-Adapter: Efficient Fine-tuning of Language Models with Zero-init Attention. ICLR, 2024. arXiv:2303.16199. DOI: https://doi.org/10.48550/arXiv.2303.16199 URL: https://arxiv.org/abs/2303.16199.

[74] DETTMERS et al, 2023. Dettmers et al., 2023), além de variantes (AdaLoRA, DoRA, adapters, prefix-tuning, prompt-tuning, (IA)3, BitFit); (b) LLMs open-source candidatos a ajuste fino (LLaMA, Llama 2, Llama 3, Mistral); (c) fundamentos de few-shot / zero-shot / chain-of-thought que justificam o uso de LLMs sem ajuste de pesos; (d) adaptação de LLMs ao domínio de tráfego / telemetria de rede (NetGPT.

[75] BROWN et al, 2005. BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J.; DHARIWAL, P. et al. Language Models are Few-Shot Learners. NeurIPS, 2020. arXiv:2005.14165. DOI: https://doi.org/10.48550/arXiv.2005.14165 URL: https://arxiv.org/abs/2005.14165.

[76] ACHIAM et al, 2023. ACHIAM, J.; ADLER, S.; AGARWAL, S.; AHMAD, L.; AKKAYA, I. et al. GPT-4 Technical Report. 2023. arXiv:2303.08774. DOI: https://doi.org/10.48550/arXiv.2303.08774 URL: https://arxiv.org/abs/2303.08774.

[77] MENG et al, 2025. MENG, X.; LIN, C.; WANG, Y.; ZHANG, Y. NetGPT: Generative Pretrained Transformer for Network Traffic. 2023 (rev. 2025.

[78] GINIGE et al, 2024. GINIGE, Y.; DAHANAYAKA, T.; HUANG, Y.; JOURJON, G.; SENEVIRATNE, S. TrafficGPT: An LLM Approach for Open-Set Encrypted Traffic Classification. Proceedings of the 19th Asian Internet Engineering Conference (AINTEC), 2024. DOI: https://doi.org/10.1145/3674213.3674217 URL: https://dl.acm.org/doi/10.1145/3674213.3674217.

[79] CUI et al, 2025. CUI, T.; LIN, X.; LI, S.; CHEN, M.; YIN, Q.; LI, Q.; XU, K. TrafficLLM: Enhancing Large Language Models for Network Traffic Analysis with Generic Traffic Representation. 2025. arXiv:2504.04222. DOI: https://doi.org/10.48550/arXiv.2504.04222 URL: https://arxiv.org/abs/2504.04222.

[80] ZHANG et al, 2023. When LLMs Meet Cybersecurity: A Systematic Literature Review.

[81] SUI et al, 2024. SUI, Y.; ZHOU, M.; ZHOU, M.; HAN, S.; ZHANG, D. Table Meets LLM: Can Large Language Models Understand Structured Table Data? A Benchmark and Empirical Study. WSDM, 2024. arXiv:2305.13062. DOI: https://doi.org/10.48550/arXiv.2305.13062 URL: https://arxiv.org/abs/2305.13062.

[82] HEGSELMANN et al, 2023. HEGSELMANN, S.; BUENDIA, A.; LANG, H.; AGRAWAL, M.; JIANG, X.; SONTAG, D. TabLLM: Few-shot Classification of Tabular Data with Large Language Models. AISTATS, 2023. arXiv:2210.10723. DOI: https://doi.org/10.48550/arXiv.2210.10723 URL: https://arxiv.org/abs/2210.10723.

[83] LIU et al, 2024. On IoT intrusion detection based on data augmentation for enhancing learning on unbalanced samples.

[84] HOULSBY et al, 1902. HOULSBY, N.; GIURGIU, A.; JASTRZEBSKI, S.; MORRONE, B.; DE LAROUSSILHE, Q.; GESMUNDO, A.; ATTARIYAN, M.; GELLY, S. Parameter-Efficient Transfer Learning for NLP. ICML, 2019. arXiv:1902.00751. DOI: https://doi.org/10.48550/arXiv.1902.00751 URL: https://arxiv.org/abs/1902.00751.

[85] LIU et al, 2022. On IoT intrusion detection based on data augmentation for enhancing learning on unbalanced samples.

[86] ESSENCIAL Danilevsky et al, 2010. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[87] ESSENCIAL Ali et al, 2023. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[88] ESSENCIAL Neupane et al, 2022. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[89] RECOMENDADO Sarker, 2024. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[90] ESSENCIAL Arrieta et al, 2019. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[91] COMPLEMENTAR Houssel et al, 2024. Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 — 38 VALIDADAS).

[92] COMPLEMENTAR Pizarro et al, 2025. Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 — 38 VALIDADAS).

[93] COMPLEMENTAR Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN. arXiv:2510.23313 (preprint), 2025. Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 — 38 VALIDADAS).

[94] ESSENCIAL Ribeiro et al, 2016. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——— 3. REFERÊNCIAS CLASSIFICADAS (.

[95] ESSENCIAL Kadavath et al, 2022. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——— 3. REFERÊNCIAS CLASSIFICADAS (.

[96] RECOMENDADO Guo et al, 2017. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[97] RECOMENDADO Lin et al, 2022. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[98] RECOMENDADO Zhu et al, 2023. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[99] ESSENCIAL Wei et al, 2022. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[100] ESSENCIAL Lundberg et al, 2017. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[101] ESSENCIAL - Dataset UNSW-NB15 (descrição oficial / paper fundador) Moustafa et al, 2015. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[102] RECOMENDADO - Dataset InSDN et al, 2020. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[103] RECOMENDADO - Data augmentation em IoT (desbalanceamento) Zhang et al, 2022. Recomendado / Complementar. - Estratégia de

paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————————— 3.
REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[104] RECOMENDADO - Geração sintética e privacy-preserving de traces Aceto et al, 2024. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————————— 3.
REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[105] ESSENCIAL - AnoLLM et al, 2025. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————————— 3.
REFERÊNCIAS CLASSIFICADAS (.

[106] RECOMENDADO - Survey LLMs em dados tabulares Fang et al, 2024. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ——————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[107] RECOMENDADO - Detecção zero-shot de anomalias tabulares com LLMs Li et al, 2024. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————————— 3.
REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[108] ESSENCIAL - Avaliação estatística do UNSW-NB15 Moustafa et al, 2016. Essencial / Recomendado / Complementar. - Estratégia de

paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[109] RECOMENDADO - Augmentation GAN para classes minoritárias em rede Kang et al, 2025. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[110] COMPLEMENTAR - Testbed híbrido SDN et al, 2023. Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 — 38 VALIDADAS).

[111] ESSENCIAL - Metodologia de geração CIC (base do CSE-CIC-IDS2018) Sharafaldin et al, 2018. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.
——————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[112] RECOMENDADO - Survey de geração sintética de tráfego de rede Synthetic Network Traffic Data Generation: A Comparative Analysis. arXiv preprint, 2024. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal.

———————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[113] ESSENCIAL - Dataset CSE-CIC-IDS2018 (descrição oficial) Canadian Institute for Cybersecurity (CIC) & Communications Security Establishment (CSE). CSE-CIC-IDS, 2018. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ———————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[114] ESSENCIAL - Survey de datasets de NIDS Ring et al, 2019. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ———————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[115] RECOMENDADO - Análise do KDD Cup 99 / NSL-KDD et al, 2009. Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ———————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (MÍNIMO 30 —.

[116] ESSENCIAL - Mininet (emulador para SDN) Lantz et al, 2010. Essencial / Recomendado / Complementar. - Estratégia de paralelização: busca distribuída em 3 eixos temáticos via subagentes (fundamentos de XAI; XAI para NIDS/HuntGPT; LLMs/calibração/ justificativa textual), consolidada e suplementada por buscas diretas do pesquisador principal. ———————————————————————————— 3. REFERÊNCIAS CLASSIFICADAS (.

[117] Rodrigues, João Pedro Santos, 2026. Projeto de pesquisa: detecção e mitigação inteligente de anomalias em redes definidas por software com LLMs open-source.