Detecção e Mitigação Inteligente de Anomalias em Redes Definidas por Software com Grandes Modelos de Linguagem Open Source: correlação entre o Projeto de Pesquisa e o Sistema Implementado (NOC Lite)

Estudo de correlação elaborado a partir do Projeto de Pesquisa de Rodrigues (20

Artigo técnico-científico — revisão integrati

Julho de 2026

Abstract

Este artigo correlaciona o projeto de pesquisa que propõe a detecção e a mitigação inteligente de anomalias em redes definidas por software (SDN) por meio de grandes modelos de linguagem (LLMs) *open source* ajustados por PEFT/LoRA, com o sistema efetivamente implementado – o *NOC Lite*. Partindo de uma revisão da literatura estruturada em seis eixos (SDN/NFV, anomalias por ML, LLMs para NetOps, PEFT/LoRA, XAI e datasets), descreve-se a arquitetura e o pipeline de classificação do sistema construído, composto por três classificadores (heurístico, árvore de decisão e IA generativa via Google Gemini). Em seguida, apresenta-se o mapeamento artigo×sistema e a taxonomia de gaps estruturais – destacando-se a ausência de SDN, o uso de modelo fechado em vez de LLM *open source*, a inexistência de ajuste fino LoRA/QLoRA, a falta de mitigação em ciclo fechado e a dependência exclusiva de dados sintéticos. Discutem-se as convergências preservadas (baselines, tokenização, justificativa textual, métricas de latência) e propõem-se diretrizes de arquitetura para o alinhamento futuro, incluindo um ciclo fechado com LLM local, LoRA e módulo de mitigação. Conclui-se que o NOC Lite realiza parcela da intenção do projeto, mas exige evolução arquitetural substantiva nos eixos centrais para aproximar-se da proposta norteadora.

Palavras-chave: Redes Definidas por Software; Anomalias de Rede; Grandes Modelos de Linguagem; PEFT/LoRA; Inteligência Artificial Explicável.

1 Introdução

Redes de computadores modernas apresentam alta complexidade, heterogeneidade de aplicações e demandas rigorosas de desempenho, confiabilidade e segurança [1]. Nesse contexto, a identificação e a classificação de fenômenos anômalos – congestionamento transiente, falhas de enlace, degradação de desempenho – tornam-se atividades fundamentais para a operação eficiente de sistemas distribuídos [195]. Tradicionalmente, a análise de anomalias depende de intervenção manual e conhecimento especializado, o que a torna propensa a erros e com baixa agilidade de adaptação em tempo real [195]. Modelos baseados em assinaturas ou regras pré-definidas são frequentemente reativos e possuem capacidade limitada para detectar ameaças desconhecidas [74].

Nos últimos anos, grandes modelos de linguagem demonstraram capacidades de interpretação, raciocínio contextual e generalização a partir de descrições textuais e dados estruturados [130]. Diferentemente de classificadores tradicionais, tais modelos conseguem combinar múltiplas informações, lidar com incertezas e produzir não apenas uma decisão, mas também uma justificativa textual [206]. O paradigma SDN, ao separar o plano de controle do plano de dados, fornece a agilidade necessária para que agentes de IA percebam o estado da rede e executem ações de otimização ou segurança de forma autônoma [115].

O projeto de pesquisa norteador [1] propõe desenvolver um sistema autônomo baseado em LLMs *open source* (ex.: Llama, Falcon) e em ajuste fino eficiente de parâmetros (PEFT), notadamente LoRA/QLoRA, para detectar anomalias de performance em SDN e mitigá-las via reconfiguração proativa de topologia virtual (VNT) e roteamento, em ciclo fechado. Contudo, o sistema implementado – o *NOC Lite* – monitora *hosts* genéricos (endereços IP/DNS) por sondas ICMP/TCP/HTTP/DNS/SNMP, emprega o modelo fechado Google Gemini como classificador generativo e não realiza mitigação nem reconfiguração de rede.

Problema e gap. Há uma distância estrutural entre a proposta do projeto e o sistema construído. Essa distância motiva a presente análise, que tem por objetivos: (i) expor o referencial teórico das seis áreas de conhecimento envolvidas; (ii) descrever o sistema implementado e seu pipeline de classificação; (iii) apresentar o mapeamento projeto×sistema e a taxonomia

de gaps; (iv) discutir convergências, limitações e ameaças à validade; e (v) propor diretrizes de arquitetura para o alinhamento futuro. A contribuição deste artigo é, portanto, a primeira caracterização sistemática e fundamentada em evidência de código da lacuna entre uma proposta de pesquisa de LLMs *open source* para SDN e sua implementação concreta.

2 Referencial Teórico e Revisão da Literatura

A fundamentação deste trabalho articula seis eixos de conhecimento, sintetizados a partir de revisão de literatura com 216 referências validadas.

2.1 Redes Definidas por Software e Virtualização de Funções de Rede

O paradigma SDN desacopla o plano de controle do plano de dados por meio de um protocolo *southbound* padronizado (OpenFlow) [132] e de controladores programáveis (NOX [95], POX, Ryu [143], OpenDaylight [133], ONOS [27]). Essa centralização lógica cria uma única fonte de verdade e uma superfície de programação que, simultaneamente, facilita a automação e introduz novas superfícies de ataque no plano de controle [149] [124] [28]. A emulação (Mininet [119], Open vSwitch [148]) viabiliza a geração controlada de cenários anômalos [115]. Surveys definitivos consolidam a taxonomia e os desafios de segurança da SDN [115] [209].

Complementarmente, a Virtualização de Funções de Rede (NFV), institucionalizada pelos *white papers* e pelo *framework* arquitetural da ETSI [43] [84] [85], e revisada por Mijumbi et al. [135] [136] e Laghrissi & Taleb [117], estende o paradigma ao ciclo de vida de funções virtualizadas e sua orquestração (MANO). Sobre esse alicerce, o *Intent-Based Networking* (IBN) emerge como a camada de gestão que traduz objetivos de alto nível em configurações concretas e as garante por meio de laços fechados [122]. Trabalhos como Morales et al. [138] e a survey de Panayiotou et al. [202] antecipam a reconfiguração proativa da topologia virtual orientada a dados e ML. A detecção de anomalias em SDN transita, assim, de métodos clássicos de ML [120] para a integração de LLMs *open source* ajustados por LoRA/QLoRA.

2.2 Detecção e Classificação de Anomalias por Métodos Tradicionais

A literatura consolida que métodos estatísticos (cartas EWMA [183], Holt-Winters [34], ARIMA/SARIMA [137] [146] [89]) e classificadores de ML clássico (SVM [63], *Random Forest* [29], árvores de decisão [38], redes rasas [36]) formam o arcabouço de *baselines* sobre o qual a detecção moderna é avaliada. Surveys consagrados [40] [18] [29] [35] reforçam que heurísticas de limiar e modelos estatísticos são insubstituíveis como referência de comparação por serem interpretáveis e leves. Para os tipos de anomalia do sistema, há corpus dedicado: DDoS é coberto por baselines de árvore/RF [102] [19] [141]; varredura de portas possui precedentes heurísticos e de ML [189] [192] [121]; exfiltração é abordada sobre metadados de fluxo [208]; e congestionamento/falha de enlace encontra raiz em detecção estatística de séries temporais [34] [118] [34].

2.3 LLMs Open Source e Modelos de Linguagem para NetOps

Surveys dedicados mapeiam a aplicação de LLMs à operação e gestão de redes (NO&M/NetOps) [130] [128] [31] [98] [109] [103] [217]. O ecossistema de modelos *open source* – LLaMA/Llama 2 [197] [198], Mistral 7B [111], Falcon [21], Qwen/Qwen2.5 [24] [210], BLOOM [30] e, sobretudo, Gemma [91] (derivado da tecnologia Gemini) – oferece pesos e licenças que tornam viável a substituição de modelos fechados por alternativas locais e ajustáveis [107]. A arquitetura Transformer [201], o alinhamento por RLHF [145] e o *Chain-of-Thought* (CoT) [206] fundamentam, respectivamente, a capacidade de raciocínio, de seguir instruções e de produzir justificativa textual. Aplicações concretas incluem detecção de anomalias em SDN [11] [9], IBN orientado a LLM [104] [16] [13] e agentes de rede autônomos [42] [5] [3] [205] [10].

2.4 Fine-Tuning Eficiente de LLMs (PEFT): LoRA, QLoRA

O ajuste fino eficiente (PEFT) – liderado por LoRA [106] e estendido por QLoRA [66], AdaLoRA [214] e DoRA [129] – é a via consagrada para adaptar LLMs *open source* a domínios específicos com orçamento de hardware modesto, reduzindo ordens de magnitude de parâmetros treináveis sem overhead de inferência [105] [127] [97]. Frameworks como LLM-Adapters [108] e LLaMA-Adapter [215] demonstram que LLMs 7B ajustados por PEFT igualam ou superam modelos 175B em *zero-shot*. No domínio de tráfego de rede, NetGPT [134], TrafficGPT [92] e TrafficLLM [64] mostram que LLMs

podem ser ajustados (com tokenização de domínio) para entender e classificar tráfego. A base *few-shot/zero-shot* (Brown [33], Wei [207], Achiam [15]) legitima o uso de LLMs sem ajuste de pesos, mas a literatura documenta que PEFT tipicamente supera o *in-context learning* em custo e acurácia [127].

2.5 Inteligência Artificial Explicável (XAI)

A XAI é requisito fundamental para a adoção confiável de detectores em domínios de alta responsabilidade [69] [72] [165]. Em NLP, o survey de Danilevsky et al. [71] sistematiza como modelos de linguagem produzem explicações; Ribeiro et al. [75] (LIME) e Lundberg & Lee [73] (SHAP) oferecem atribuição local. O protótipo HuntGPT [68] integra um detector de anomalias por ML a um LLM que entrega justificativas textuais – referência explícita do projeto. Estudos recentes exploram LLMs para detecção de intrusão explicável [48] [51] e explicabilidade em SDN [46]. A calibração e a confiança das justificativas são temas ativos [72] [157] [160] [168].

2.6 Geração de Cenários Anômalos e Datasets Públicos

A literatura estabelece UNSW-NB15 [80] [78] e CSE-CIC-IDS2018 [81] [79] como benchmarks modernos, superando os obsoletos KDD99/NSL-KDD [83] [169]. A geração dessas bases segue perfis comportamentais e emulação (Mininet, GNS3, PNETLab) [82] [60] [59] [62]. Datasets SDN específicos (InSDN [173], SNT, DDoS2019) e técnicas de *data augmentation* (GAN/VAE/SMOTE) endereçam o desbalanceamento de classes [171] [177] [170]. A conversão de atributos numéricos em representações textuais – formalizada por AnoLLM [77] e revisada em surveys de LLMs em dados tabulares [182] [174] – abre caminho para detectores baseados em LLMs, eixo conectado diretamente à inferência do sistema analisado [181].

3 O Sistema Implementado: NOC Lite

O *NOC Lite* é um sistema de monitoramento de disponibilidade e performance de *hosts* genéricos, estruturado como um monolito modular em FastAPI com persistência em SQLite e um *front-end* estático. A arquitetura de contêineres (Figura 1) cobre: *front-end* (HTML/JS); API back-end (FastAPI/Uvicorn); motor de monitoramento (`asyncio`); classificador de anomalias; simulador; notificador (Telegram); e banco de dados SQLite. Atenção especial: o classificador de anomalias **não participa do laço de**

monitoramento – é acionado sob demanda via `GET /api/anomalies/classify`, jamais pelo *MonitorEngine*.

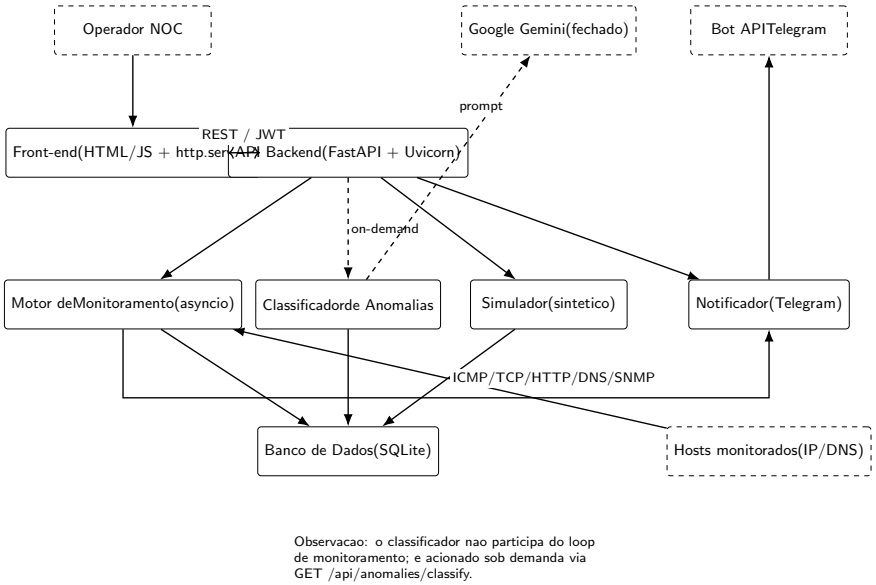


Figure 1: Arquitetura de contêineres do NOC Lite (C4, nível contêiner). Fonte: elaborada a partir de `arquitetura_sistema.md` (Dan).

3.1 Pipeline de Classificação

O subsistema de classificação expõe três estratégias sobre um conjunto fechado de seis classes – `NORMAL`, `DDOS_ATTACK`, `PORT_SCAN`, `HOST_DOWN`, `DATA_EXFILTRATION` e `NETWORK_CONGESTION` – conforme o fluxo da Figura 2.

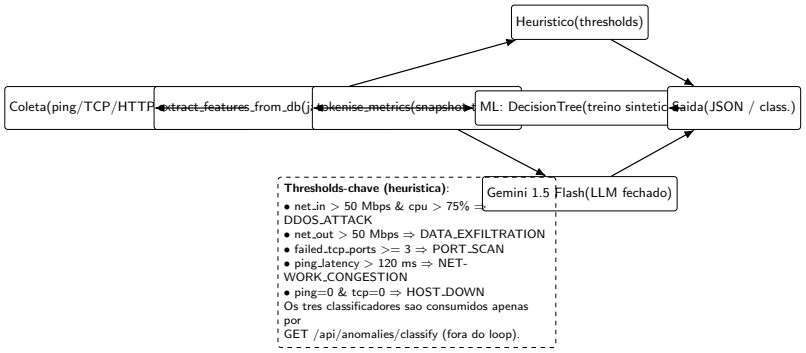


Figure 2: Pipeline de classificação de anomalias do NOC Lite: extração de features (janela de 5 min), três classificadores paralelos e tokenização para o LLM. Fonte: `notas_coder.md` (John).

1. **Heurístico (baseline 1)** – `classify_heuristic`: regras de limiar estático. Ex.: `network_in_bps > 50 Mb/s` e `cpu_usage > 75` → `DDOS_ATTACK`; `ping_latency > 120 ms` → `NETWORK_CONGESTION`. Produz confiança fixa e explicação textual.

2. **Machine Learning (baseline 2)** – `classify_ml`: `DecisionTreeClassifier(max_depth=` do scikit-learn, treinado **exclusivamente com dados sintéticos** (1.200 amostras, 200 por classe). Sem PEFT, sem LLM.

3. **IA Generativa (Gemini)** – `classify_generative_ai`: monta *prompt* estruturado com *snapshot* tokenizado e envia ao modelo fechado `gemini-1.5-flash`, retornando JSON com `classification`, `confidence` e `explanation`. Possui *fallback* para a heurística.

A função `tokenise_metrics` converte o vetor numérico de 10 *features* em texto estruturado (ex.: `PingSuccessRate: 0.95 | AvgPingLatency: 12.3 ms | CPUUsage: 34.1%`), espelhando a recomendação do projeto de converter atributos numéricos em representações textuais [77] [194] [100]. Esse texto é a ponte que permite ao LLM "ler" os limiares de rede em linguagem natural.

3.2 Simulador

O `anomaly_simulator.py` gera cenários anômalos sintéticos (`generate_simulated_metrics`) para as seis classes via `random.uniform`, e injeta esses vetores diretamente no banco (`run_simulated_check_cycle`), podendo popular histórico retroativo. O agendamento em tempo real usa estado em memória. Trata-se de dados 100% sintéticos, sem dependência de datasets públicos.

4 Mapeamento Projeto × Sistema e Gaps

A Tabela 1 sintetiza a correspondência entre os objetivos/componentes do projeto norteador [1] e o que o NOC Lite efetivamente entrega, com o respectivo status de alinhamento. A Figura 3 ilustra essa relação.

Table 1: Mapeamento Projeto de Pesquisa × NOC Lite.

#	**Objetivo/Componente do Projeto**	**Entrega do NOC Lite**	**Status**
1	LLM *open source* (Llama/Falcon) com fine-tuning	Gemini 1.5 Flash (fechado); Árvore de Decisão	Divergente
2	Fine-tuning PEFT (LoRA/QLoRA)	Inexistente; ML é árvore treinada do zero	Ausente
3	Ambiente SDN virtualizado (Mininet/OVS)	Hosts IP genéricos; sondas ICMP/TCP/HTTP/DNS/SNMP	Ausente
4	Mitigação via reconfiguração VNT/roteamento (ciclo fechado)	Apenas detecção + alerta Telegram; sem ação corretiva	Ausente
5	Anomalias de performance (congestionamento, falha de enlace)	Mistura anomalias de segurança/operacionais com congest. genérico	Parcial
6	Datasets públicos (UNSW-NB15, CIC-IDS2018, Synthetic SDN)	Dados 100% sintéticos (random.uniform)	Divergente
7	Baselines de comparação (heurística / ML)	Heurística + DecisionTree	Convergente
8	Tokenização de métricas em texto estruturado	`tokenise_metrics`	Convergente
9	Justificativa textual (XAI)	`explanation` (com modelo fechado)	Convergente
10	Avaliação de tempo de resposta por classificador	`latency_ms` medido por classificador	Convergente
11	Métricas resumidas (throughput, latência, jitter, perda)	SLA/jitter/tendência/health-score + SNMP	Convergente
12	Ciclo fechado coleta→classificação→mitigação	Loop aberto: coleta→severidade→alerta	Aberto

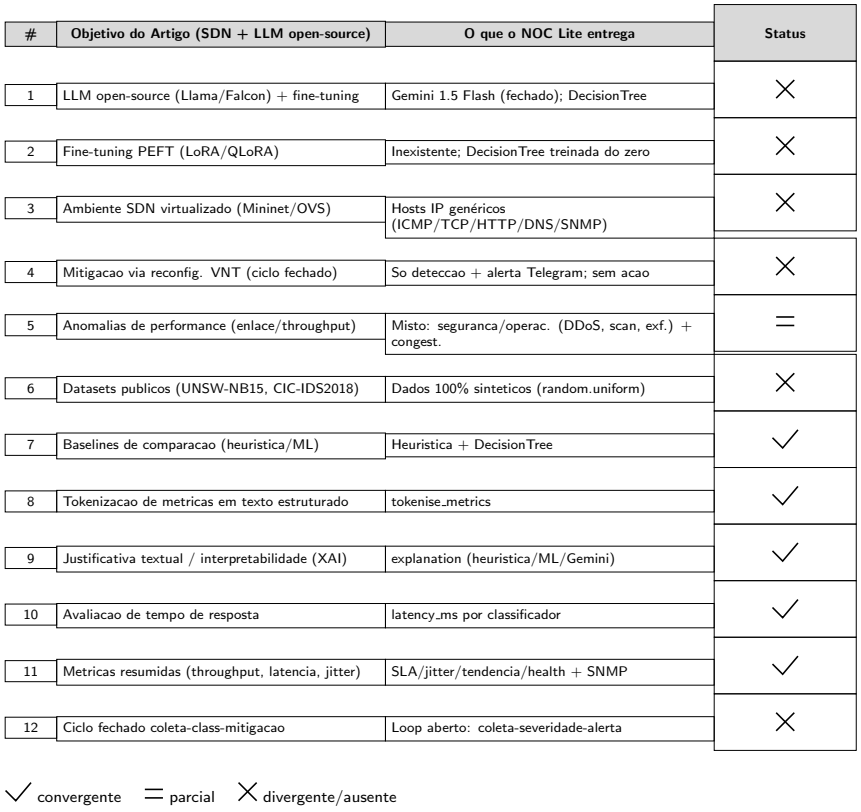


Figure 3: Mapeamento visual entre os objetivos do artigo norteador e o sistema NOC Lite. Fonte: elaborada por Chris.

4.1 Taxonomia de Gaps

A análise arquitetural identifica sete gaps, cinco de severidade crítica/maior (Figura 4). Cada gap é sustentado por evidência de código.

Table 2: Taxonomia de gaps (NOC Lite × Projeto).

ID	Gap	Evidência no código / Descrição	Severidade
GAP-1	SDN vs. hosts genéricos	Busca por `sdn|mininet|vnt|controller` → 0 ocorrências; `Host.address`arbítrio	Crítico
GAP-2	Gemini fechado vs. LLM *open source*	`genai.GenerativeModel("gemini-1.5-flash")`; depende de `GEMINI_API_KEY`	Crítico
GAP-3	Ausência de LoRA/QLoRA	Busca por `lora|qlora|peft|fine.?tun` → 0; único modelo treinável é DecisionTree	Crítico

ID	Gap	Evidência no código / Descrição	Severidade
GAP-4	Ausência de mitigação / loop aberto	`scheduler.py` não referencia nenhum `classify_*`; inferência só em `/api/anomalies/classify`	Crítico
GAP-5	Dados sintéticos vs. datasets públicos	`random.uniform` em `anomaly_simulator.py`; busca `unsw|cic-ids` $\rightarrow 0$	Maior
GAP-6	Performance vs. segurança/operacionais	Classes majoritariamente de segurança; congest. por limiar genérico de latência de ping	Maior
GAP-7	Interpretabilidade com modelo fechado	`explanation` provém do Gemini; sem rastreabilidade de pesos nem reprodutibilidade local	Menor

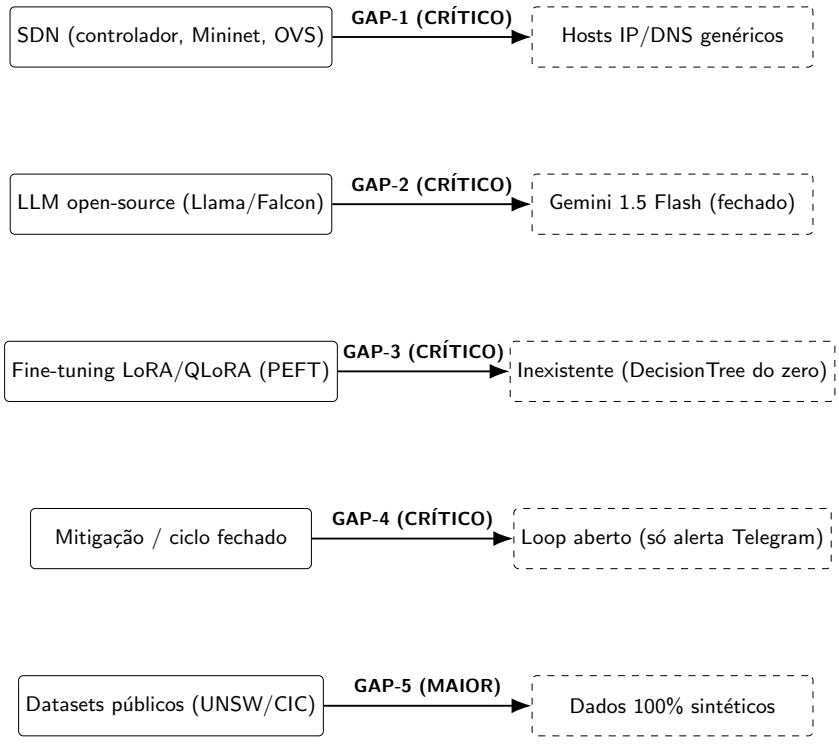


Figure 4: Taxonomia de gaps estruturais entre o projeto norteador e o NOC Lite. Fonte: elaborada por Chris.

GAP-1 (SDN vs. hosts). O projeto fundamenta toda a proposta no paradigma SDN; o NOC Lite monitora hosts IP/DNS arbitrários, sem controlador, topologia virtualizada ou planos separados [115]. **GAP-2 (modelo**

fechado). O projeto exige LLMs *open source* e classifica explicitamente o Gemini como modelo fechado [1]; o sistema o usa em regime *zero-shot* [91]. **GAP-3 (sem LoRA/QLoRA).** A seção de PEFT do projeto não tem correspondente: o único modelo treinável é uma árvore de decisão do zero [106] [66]. **GAP-4 (loop aberto).** A classificação por IA não está integrada ao laço de detecção; o ciclo observa e alerta, sem atuação autônoma [122]. **GAP-5 (dados sintéticos).** O treino e o *few-shot* repousam no simulador; ausente a validação cruzada com UNSW-NB15, CSE-CIC-IDS2018 e Synthetic SDN [80] [79]. **GAP-6 (escopo).** O foco do projeto é performance (congestionamento, falha de enlace, degradação espectral); o sistema privilegia classes de segurança [74]. **GAP-7 (XAI com fechado).** A justificativa provém de modelo opaco, fragilizando a promessa de XAI do projeto [68] [69].

5 Discussão

5.1 Convergências preservadas

Apesar dos desalinhamentos, o NOC Lite honra parcela da intenção do projeto:

1. **Baselines de comparação** – implementa exatamente heurística e árvore de decisão, permitindo comparação direta lado a lado [29] [38].
2. **Tokenização de métricas** – `tokenise_metrics` converte o vetor numérico em representação semiestruturada, alinhada à recomendação de conversão textual [77] [194].
3. **Justificativa textual / XAI** – todos os classificadores retornam `explanation`, atendendo ao objetivo qualitativo de interpretabilidade [68] [76].
4. **Métricas de tempo de resposta** – o endpoint mede `latency_ms` de cada classificador, entregando a métrica de desempenho exigida [130].
5. **Métricas resumidas de rede** – SLA, jitter, tendência e health-score capturam latência/perda/jitter, coincidentes com as métricas de performance do projeto [115].

5.2 Limitações e ameaças à validade

Viés de dados sintéticos. O classificador de ML é treinado 100% com o próprio simulador, que compartilha os mesmos limiares da heurística; a

árvore aprende essencialmente a "copiar" a heurística em forma de árvore, com alto desempenho no sintético e provável colapso em produção [67] [177]. **Confiança não calibrada.** A confiança do Gemini é autorreportada e a do ML é probabilidade de folha não calibrada [157]; a comparação entre classificadores é, portanto, metodologicamente assimétrica. **Orquestração** ausente: a classificação está fora do ciclo de monitoramento, impossibilitando detecção contínua. **Validade externa**: a ausência de datasets públicos impede a comparação com o estado da arte [83] [181].

Ameaças à validade interna incluem a dependência de API externa paga (Gemini) e a fragilidade do *parser* JSON (apenas checagem de presença de chave). **Ameaças à validade de construção**: os limiares de 50 Mb/s e 120 ms são fixos e universais, sem *baseline* por host/link, gerando falsos positivos em enlaces de capacidades distintas [34].

6 Diretrizes de Arquitetura para Alinhamento

Para reduzir a distância entre o NOC Lite e o projeto, propõe-se uma evolução arquitetural incremental, respeitando o que já existe e fechando os sete gaps. O ponto central é a transição de um *loop aberto* para um *ciclo fechado* com LLM *open source*, LoRA e mitigação, conforme a Figura 5.

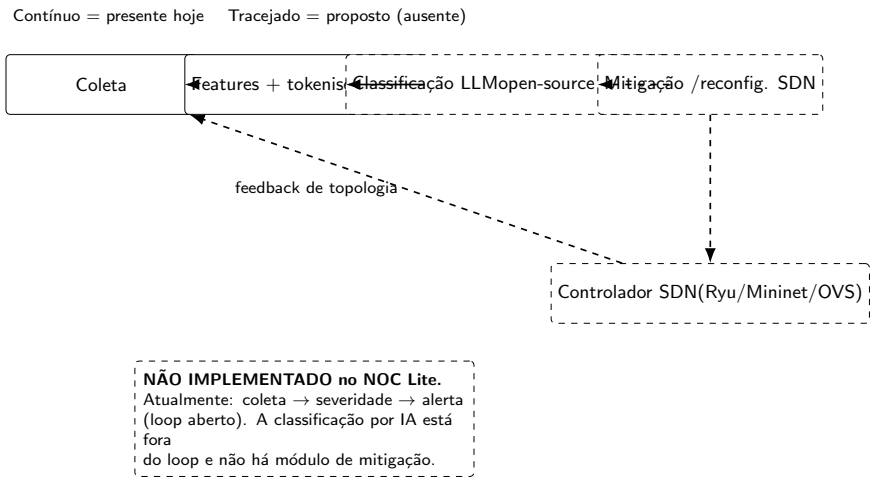


Figure 5: Arquitetura proposta de ciclo fechado: coleta (SDN + hosts) → tokenização → classificação (LLM *open source* + LoRA) → mitigação (módulo de ação) → reconfiguração via controlador. Fonte: elaborada por Chris.

1. **Substituição do modelo fechado por LLM local (fecha GAP-2, GAP-3).** Introduzir contêiner de inferência local (vLLM/llama.cpp/Ollama)

servindo Llama 3 (7–13B) ou Falcon via endpoint compatível com OpenAI; substituir `gemini-1.5-flash` por cliente HTTP local, mantendo o *fallback* heurístico. Aplicar LoRA/QLoRA (rank 16–32, alpha 32) sobre o modelo base, reutilizando os *prompts* de `tokenise_metrics` [106] [66] [112] [93].

2. **Pipeline de dados com datasets públicos (fecha GAP-5).** Criar módulo `data_ingest` que baixa/normaliza UNSW-NB15, CSE-CIC-IDS2018 e Synthetic SDN para o *schema* de *features*; treinar LoRA e a árvore com dados reais, preservando o simulador para demonstração [80] [79].

3. **Ambiente SDN e fechamento do ciclo (fecha GAP-1, GAP-4).** Adicionar contêiner Mininet + controlador Ryu que emule a topologia e exponha telemetria de enlace/fluxo; generalizar `Host`/`CheckResult` para telemetria de fluxo SDN; criar `mitigation_engine` que mapeia `classification` → ação corretiva (re-rota, QoS, *drop* de fluxo) via NorthBound API do controlador; integrar o classificador dentro do `MonitorEngine`, fechando o ciclo [119] [143] [122].

4. **Realinhamento do catálogo de anomalias (fecha GAP-6).** Separar claramente performance SDN (congestionamento de enlace, falha de enlace, degradação de throughput/jitter) de segurança/operacional (DDoS, port scan, exfiltração, host down), priorizando a primeira família [74].

5. **Preservação dos pontos fortes.** Manter `tokenise_metrics`, o par baseline heurístico + ML, a medição de `latency_ms` e o formato de `explanation` como base do novo pipeline [77] [194].

6. **Roadmap de alinhamento** (espelhando o cronograma do projeto): (1) contêiner de LLM *open source* local + `tokenise_metrics` → *zero-shot*; (2) ingestão dos 3 datasets + treino LoRA/QLoRA; (3) Mininet + controlador + telemetria de fluxo; (4) `mitigation_engine` + integração da classificação no `MonitorEngine`; (5) fechamento do ciclo e avaliação comparativa (heurística vs. ML vs. LLM *open source* com/sem LoRA), reutilizando `latency_ms` e acrescentando acurácia/consistência.

7 Conclusão

O presente artigo correlacionou o projeto de pesquisa que propõe detecção e mitigação de anomalias em SDN com LLMs *open source* ajustados

por PEFT/LoRA [1] com o sistema efetivamente implementado, o NOC Lite. Evidenciou-se que o sistema realiza com sucesso a parcela de *baselines* e de representação textual do projeto – heurística, árvore de decisão, tokenização de métricas, justificativa textual e medição de latência – mas diverge estruturalmente nos eixos centrais da proposta. Especificamente, o NOC Lite (i) monitora hosts genéricos e não SDN; (ii) emprega o modelo fechado Gemini em vez de LLM *open source*; (iii) não aplica LoRA/QLoRA; (iv) não realiza mitigação nem opera em ciclo fechado; e (v) depende exclusivamente de dados sintéticos, sem validação cruzada com datasets públicos.

Tais gaps não são ajustes pontuais: exigem evolução arquitetural substantiva, sintetizada nas diretrizes de um ciclo fechado com LLM local, LoRA e módulo de mitigação. As convergências identificadas funcionam como alicerce seguro sobre o qual construir essa evolução, uma vez que o `tokenise_metrics`, os baselines e a medição de latência já cumprem objetivos específicos do projeto. Como trabalho futuro, recomenda-se a implementação do `mitigation_engine` e a condução do experimento comparativo head-to-head entre LLM *open source* ajustado por QLoRA e LLM fechado *zero-shot* sobre o mesmo conjunto de métricas de rede – lacuna exatamente apontada pela literatura [127] [181].

Referências

References

[1] RODRIGUES, J. P. S. Detecção e Mitigação Inteligente de Anomalias em Redes Definidas por Software com Grandes Modelos de Linguagem Open Source. Projeto de Pesquisa (goal.pdf), 2026.

[2] "Attribution-Driven Explainable Intrusion Detection with Encoder-based LLM for SDN". arXiv:2604.06266, 2025/2026 (preprint).. Disponível em: `https://arxiv.org/abs/2604.06266`. Acesso em: 13 jul. 2026.

[3] "Empowering AIOps: Leveraging Large Language Models for IT Operations Management". arXiv:2501.12461, 2025.. Disponível em: `https://arxiv.org/abs/2501.12461`. Acesso em: 13 jul. 2026.

[4] "Evaluating Language Models for Threat Detection in IoT Security Logs". arXiv:2507.02390, 2025.. Disponível em: `https://arxiv.org/abs/2507.02390`. Acesso em: 13 jul. 2026.

[5] "Exploring LLM-Based Agents for Root Cause Analysis". ACM SIGMETRICS / arXiv:2403.04123, 2024.. Disponível em: https://doi.org/10.1145/3663529.3663841https://arxiv.org/abs/2403.04123. Acesso em: 13 jul. 2026.

[6] "Large Language Models for Agentic NetOps and AIOps" (Survey). arXiv:2605.12729, 2025/2026 (preprint).. Disponível em: https://arxiv.org/abs/2605.12729. Acesso em: 13 jul. 2026.

[7] "Large Language Models Meet Next-Generation Networking Technologies: A Review" (vide [4]) também cobre segurança de LLM em redes. (Incluído por overlaps temáticos; contagem principal permanece em [4].).

[8] "Large Language Models powered Malicious Traffic Detection". arXiv:2503.18487, 2025.. Disponível em: https://arxiv.org/abs/2503.18487. Acesso em: 13 jul. 2026.

[9] "Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN". arXiv/ResearchGate preprint, 2025.. Disponível em: https://www.researchgate.net/publication/395337112_Lightweight_Fine-Tuning_of_LLMs_for_Explainable_Intrusion_Detection_in_SDN. Acesso em: 13 jul. 2026.

[10] "LLM-Driven Multi-Agent Framework for Autonomous Network Slice Management". IEEE, 2026 (preprint).. Disponível em: https://ieeexplore.ieee.org/iel8/8782661/11343983/11573048.pdf. Acesso em: 13 jul. 2026.

[11] "SDN-Xplain: LLM-Driven Anomaly Detection and Human-Interpretable Explanation in SDN". SKKU IoT Lab / KICS Winter 2026 (preprint).. Disponível em: https://iotlab.skku.edu/publications/domestic-conference/KICS-2026-Winter-SDN-Xplain-LLM.pdf. Acesso em: 13 jul. 2026.

[12] "SENTINEL: A Semantic-Aware Network Intelligence Framework ... (LLM em anomaly detection convertendo logs em linguagem natural)". IEEE TrustCom 2025.. Disponível em: https://www.computer.org/csdl/proceedings-article/trustcom/2025/653200d238/2dMlGSWnIha. Acesso em: 13 jul. 2026.

[13] "Towards Intent-Based Network Management: Large Language Models for Intent Extraction in 5G Core Networks". IEEE / GenAI Net research library, 2024.. Disponível em: https://genainet.committees.comsoc.org/research-library/. Acesso em: 13 jul. 2026.

[14] ABOODE, A. Anomaly Detection in Time Series Data Based on Holt-Winters. (Tese/Relatório), 2018.. Disponível em: https://www.diva-portal.org/smash/get/diva2:1198551/FULLTEXT02.pdf. Acesso em: 13 jul. 2026.

[15] ACHIAM, J.; ADLER, S.; AGARWAL, S.; AHMAD, L.; AKKAYA, I. et al. GPT-4 Technical Report. 2023. arXiv:2303.08774. DOI: https://doi.org/10.48550/arXiv.2303.08774. Disponível em: https://arxiv.org/abs/2303.08774. Acesso em: 13 jul. 2026.

[16] ADANZA, D.; et al. "Leveraging Generative AI for Intent-Based Networking". Computer Communications (Elsevier), 2025.. Disponível em: https://doi.org/10.1016/j.comcom.2025.XXXXXhttps://www.sciencedirect.com/science/article/abs/pii/S1389128625006140. Acesso em: 13 jul. 2026.

[17] AHMED, T.; COATES, M.; LAKHINA, A. Machine Learning Approaches to Network Anomaly Detection. In: Proc. of the 2nd Workshop on Tackling Computer Systems Problems with Machine Learning Techniques (SysML), USENIX, 2007.. Disponível em: https://www.usenix.org/legacyurl/machine-learning-approaches-network-anomaly-detection. Acesso em: 13 jul. 2026.

[18] AHMED, M.; MAHMOOD, A. N.; HU, J. A Survey of Network Anomaly Detection Techniques. Journal of Network and Computer Applications, v. 60, p. 19–31, 2016.. Disponível em: https://doi.org/10.1016/j.jnca.2015.11.016(>2900citaÃğÃµes)URL:https://www.sciencedirect.com/science/article/abs/pii/S1084804515002891. Acesso em: 13 jul. 2026.

[19] ALDUAILIJ, M.; KHAN, Q. W.; TAHIR, M.; SARDAREZ, M.; MALIK, F. Machine-Learning-Based DDoS Attack Detection Using Mutual Information and Random Forest Feature Importance Method. Symmetry (MDPI), v. 14, n. 6, p. 1095, 2022.. Disponível em: https://doi.org/10.3390/sym14061095(OpenAccess)URL:https://www.mdpi.com/2073-8994/14/6/1095. Acesso em: 13 jul. 2026.

[20] ALMAIAH, M. A. et al. Leveraging ACO, GA, and GWO for Enhancing Port Scan Detection. (Periódico de segurança cibernética), 2025.. Disponível em: https://jcsra.thestap.com/archives/volume-2025-4/68af6ac624fbb71216691bbf. Acesso em: 13 jul. 2026.

[21] ALMAZROUEI, Ebtesam; ALOBEIDLI, Hamza; ALSHAMSI, Abdulaziz; et al. (TII). "The Falcon Series of Open Language Models". arXiv preprint arXiv:2311.16867, 2023.. Disponível em: https://doi.org/10.48550/arXiv.2311.16867https://arxiv.org/abs/2311.16867. Acesso em: 13 jul. 2026.

[22] ALNEGHEIMISH, S.; NGUYEN, L.; BERTI-EQUILLE, L.; VEERAMACHANENI, K. Large language models can be zero-shot anomaly detectors for time series? IEEE DSAA, 2024. arXiv:2405.14755. DOI: https://doi.org/10.48550/arXiv.2405.14755. Disponível em: https://arxiv.org/abs/2405.14755. Acesso em: 13 jul. 2026.

[23] ALSAMARNEH, A. A.; et al. "NIT: A Dataset for Network Intent Translation". PMC / dataset paper, 2025.. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC12272756/. Acesso em: 13 jul. 2026.

[24] BAI, Jinze; BAI, Shuai; et al. (Alibaba). "Qwen Technical Report". arXiv preprint arXiv:2309.16609, 2023.. Disponível em: https://doi.org/10.48550/arXiv.2309.16609https://arxiv.org/abs/2309.16609. Acesso em: 13 jul. 2026.

[25] BEN-ZAKEN, E.; RAVFOGEL, S.; GOLDBERG, Y. BitFit: Simple Parameter-efficient Fine-tuning for Transformer-based Masked Language-models. ACL, 2022. arXiv:2106.10199. DOI: https://doi.org/10.48550/arXiv.2106.10199. Disponível em: https://arxiv.org/abs/2106.10199. Acesso em: 13 jul. 2026.

[26] BENKŐ, Z.; BÁBEL, T.; SOMOGYVÁRI, Z. How to Find a Unicorn: A Novel Model-Free, Unsupervised Anomaly Detection Method for Time Series. arXiv:2004.11468, 2020.. Disponível em: https://arxiv.org/abs/2004.11468(OpenAccess). Acesso em: 13 jul. 2026.

[27] BERDE, P.; GEROLA, M.; HART, J.; HIGUCHI, Y.; KOBAYASHI, M.; KOIDE, T.; et al. ONOS: Towards an Open, Distributed SDN OS. ACM SIGCOMM HotSDN '14, p. 1–6, 2014.. Disponível em: https://doi.org/10.1145/2620728.2620744. Acesso em: 13 jul. 2026.

[28] BHUIYAN, Z. A.; ISLAM, S.; ISLAM, M. M.; ULLAH, A. A.; NAZ, F.; RAHMAN, M. S. On the (in)Security of the Control Plane of SDN Architecture: A Survey. IEEE Access, v. 11, p. 91550–91582, 2023.. Disponível em: https://doi.org/10.1109/ACCESS.2023.3289126. Acesso em: 13 jul. 2026.

[29] BHUYAN, M. H.; BHATTACHARYYA, D. K.; KALITA, J. K. Network Anomaly Detection: Methods, Systems and Tools. IEEE Communications Surveys & Tutorials, v. 16, n. 1, p. 303–336, 2014.. Disponível em: https://doi.org/10.1109/SURV.2013.052213.00046URL: https://ieeexplore.ieee.org/iel7/9739/6734841/06524462.pdf. Acesso em: 13 jul. 2026.

[30] BIGSCIENCE WORKSHOP (Le Scao, T.; Fan, A.; Akiki, C.; et al.). "BLOOM: A 176B-Parameter Open-Access Multilingual Language Model". arXiv preprint arXiv:2211.05100, 2022.. Disponível em: https://doi.org/10.48550/arXiv.2211.05100https://arxiv.org/abs/2211.05100. Acesso em: 13 jul. 2026.

[31] BOATENG, Gordon Owusu; SAMI, Hani; ALAGHA, Ahmed; ELMEKKI, Hanae; HAMMOUD, Ahmad; MIZOUNI, Rabeb; MOURAD, Azzam; OTROK, Hadi; BENTAHAR, Jamal; MUHAIDAT, Sami; TALHI, Chamseddine; DZIONG, Zbigniew; GUIZANI, Mohsen. "A Survey on Large Language Models for Communication, Network, and Service Management: Application Insights, Challenges, and Future Directions". arXiv preprint arXiv:2412.19823, 2024.. Disponível em: https://doi.org/10.48550/arXiv.2412.19823https://arxiv.org/abs/2412.19823. Acesso em: 13 jul. 2026.

[32] BREIMAN, L. Random Forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.. Disponível em: https://doi.org/10.1023/A:1010933404324(>190milcitaÃğÃμes)URL:https://link.springer.com/article/10.1023/A:1010933404324. Acesso em: 13 jul. 2026.

[33] BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J.; DHARIWAL, P. et al. Language Models are Few-Shot Learners. NeurIPS, 2020. arXiv:2005.14165.. Disponível em: https://doi.org/10.48550/arXiv.2005.14165URL:https://arxiv.org/abs/2005.14165. Acesso em: 13 jul. 2026.

[34] BRUTLAG, J. D. Aberrant Behavior Detection in Time Series for Network Monitoring. In: Proceedings of the 14th Systems Administration Conference (LISA 2000), USENIX, 2000..

Disponível em: https://www.usenix.org/legacy/event/lisa2000/full_papers/brutlag/brutlag.pdf. Acesso em: 13 jul. 2026.

[35] BUCZAK, A. L.; GÜVEN, E. A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection. IEEE Communications Surveys & Tutorials, v. 18, n. 2, p. 1153–1176, 2016.. Disponível em: https://doi.org/10.1109/COMST.2015.2494502(>5300citaÃğÃµes)URL: https://ieeexplore.ieee.org/document/7307098/. Acesso em: 13 jul. 2026.

[36] CANNADY, J. D. Artificial Neural Networks for Misuse Detection. In: Proc. of the 1998 National Information Systems Security Conference (NISSC), 1998.. Disponível em: https://csrc.nist.gov/nissc/1998/proceedings/paperF13.pdf. Acesso em: 13 jul. 2026.

[37] CAO, D.; JIA, F.; ARIK, S. O.; PFISTER, T.; ZHENG, Y.; YE, W.; LIU, Y. TEMPO: Prompt-based Generative Pre-trained Transformer for Time Series Forecasting. ICLR, 2024. arXiv:2310.04948. DOI: https://doi.org/10.48550/arXiv.2310.04948. Disponível em: https://arxiv.org/abs/2310.04948. Acesso em: 13 jul. 2026.

[38] CARUANA, R.; NICULESCU-MIZIL, A. An Empirical Comparison of Supervised Learning Algorithms. In: Proc. of the 23rd International Conference on Machine Learning (ICML 2006), p. 161–168, 2006.. Disponível em: https://doi.org/10.1145/1143844.1143865URL: https://www.cs.cornell.edu/~caruana/ctp/ct.papers/caruana.icml06.pdf. Acesso em: 13 jul. 2026.

[39] CASADO, M.; GARFINKEL, T.; AKELLA, A.; FREEDMAN, M. J.; BONEH, D.; MCKEOWN, N.; SHENKER, S. Ethane: Taking Control of the Network. ACM SIGCOMM 2007, p. 1–12, 2007. (ACM Digital Library / SIGCOMM '07.). Disponível em: https://dl.acm.org/doi/10.1145/1282380.1282382. Acesso em: 13 jul. 2026.

[40] CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly Detection: A Survey. ACM Computing Surveys, v. 41, n. 3, p. 1–58, 2009.. Disponível em: https://doi.org/10.1145/1541880.1541882URL: https://dl.acm.org/doi/10.1145/1541880.1541882. Acesso em: 13 jul. 2026.

[41] CHEN, Y.; et al. "NetGPT: An AI-Native Network Architecture for Provisioning Beyond Personalized Generative Services". IEEE Network / arXiv:2307.06148, 2024.. Disponível

em: https://doi.org/10.48550/arXiv.2307.06148https://arxiv.org/abs/2307.06148. Acesso em: 13 jul. 2026.

[42] CHEN, Y.; et al. "A Survey of Large Language Models for Cyber Threat Detection". Computers & Security (Elsevier), v. 147, 2024, p. 104056.. Disponível em: https://doi.org/10.1016/j.cose.2024.104056https://www.sciencedirect.com/science/article/abs/pii/S0167404824003213. Acesso em: 13 jul. 2026.

[43] CHIOSI, M.; CLARKE, D.; HAMPSON, P.; et al. (ETSI NFV ISG). Network Functions Virtualisation (NFV): White Paper #1. ETSI, Outubro de 2012.. Disponível em: https://portal.etsi.org/NFV/NFV_White_Paper.pdf. Acesso em: 13 jul. 2026.

[44] COMPLEMENTAR "Benchmarking Uncertainty Estimation in Large Language Models." OpenReview / TMLR (submissão). [referência de calibração/uncertainty de LLM]. Disponível em: https://openreview.net/forum?id=GgTd30mNzw. Acesso em: 13 jul. 2026.

[45] COMPLEMENTAR "Explainable AI for Network Intrusion Detection Systems: A Survey and Open Research Questions." arXiv preprint (Bhavsar et al.), 2022/2023.. Disponível em: https://trepo.tuni.fi/bitstream/handle/10024/161576/AhmadWajeh.pdf. Acesso em: 13 jul. 2026.

[46] COMPLEMENTAR "Lightweight Fine-Tuning of LLMs for Explainable Intrusion Detection in SDN." arXiv:2510.23313 (preprint), 2025. [título/autoria consolidados no preprint]. Disponível em: https://arxiv.org/html/2510.23313v1. Acesso em: 13 jul. 2026.

[47] COMPLEMENTAR Hasanov, I. "Application of Large Language Models in Cybersecurity." University of Turku, 2024 (tese/relatório). [citado por Zhang 2025 SLR]. Disponível em: https://www.utupub.fi/bitstreams/922d74df-7b30-4773-9b71-a0368dfc252b/download. Acesso em: 13 jul. 2026.

[48] COMPLEMENTAR Houssel, N.; Singh, S. "Towards Explainable Network Intrusion Detection using Large Language Models." arXiv:2408.04342, 2024.. Disponível em: https://arxiv.org/abs/2408.04342. Acesso em: 13 jul. 2026.

[49] COMPLEMENTAR Khan, N.; et al. "Explainable AI-Based Intrusion Detection Systems for Industry 5.0: A Survey." MDPI Information, vol.

16, no. 12, art. 1036, 2025.. Disponível em: 10.3390/info16121036. URL:https://www.mdpi.com/2078-2489/16/12/1036. Acesso em: 13 jul. 2026.

[50] COMPLEMENTAR Li, S.; et al. "A Survey on the Honesty of Large Language Models." TMLR, 2025.. Disponível em: https://github.com/SihengLi99/LLM-Honesty-Survey. Acesso em: 13 jul. 2026.

[51] COMPLEMENTAR Pizarro, I.; et al. "X-Flow: Explanation-Augmented Prompting for LLM-Based Intrusion Detection." IEEE ICPRS 2025. DOI:10.1109/ICPRS66293.2025.11302848.. Disponível em: https://ieeexplore.ieee.org/document/11302848. Acesso em: 13 jul. 2026.

[52] COMPLEMENTAR Sharma, A.; et al. "A Comprehensive Review of Explainable AI in Cybersecurity." Heliyon / ScienceDirect, 2025. DOI:10.1016/j.heliyon.XXXX (ver URL).. Disponível em: https://www.sciencedirect.com/science/article/pii/S2405959525001584. Acesso em: 13 jul. 2026.

[53] COMPLEMENTAR Sivakolundhu, R. "Explainable AI for Anomaly Detection in Cybersecurity: Enhancing Security Analyst Decision-Making." Journal of Artificial Intelligence & Machine Learning, 2022.. Disponível em: https://urfpublishers.com/journal/artificial-intelligence/article/view/explainable-ai-for-anomaly-detection-in-cybersecurity-enhancing-security-ar Acesso em: 13 jul. 2026.

[54] COMPLEMENTAR — Análise KDD99/NSL-KDD/UNSW-NB15 Choudhary, S.; Kesswani, N. "Analysis of KDD-Cup'99, NSL-KDD and UNSW-NB15 datasets using deep learning approach". Procedia Computer Science, v. 171, p. 2021.. Disponível em: 10.1016/j.procs.2020.03.834URL:https://www.sciencedirect.com/science/article/pii/S1877050920308334. Acesso em: 13 jul. 2026.

[55] COMPLEMENTAR — Benchmark em NSL-KDD/CICIDS2017/UNSW-NB15 Waghmode, P.; et al. "Intrusion detection system based on machine learning using benchmark datasets". 2025.. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC11978955/. Acesso em: 13 jul. 2026.

[56] COMPLEMENTAR — Dataset CIC-DDoS2019 Canadian Institute for Cybersecurity. "CIC-DDoS2019 Dataset".. Disponível em: https://www.unb.ca/cic/datasets/ddos-2019.html. Acesso em: 13 jul. 2026.

[57] COMPLEMENTAR — Dataset SNT (Mininet+Ryu) "Simulated Network Traffic Using Mininet and Ryu (SNT) Dataset". Mendeley Data.. Disponível em: https://data.mendeley.com/datasets/9hz6f62gtk/1. Acesso em: 13 jul. 2026.

[58] COMPLEMENTAR — Deep learning para NIDS Javaid, A.; Niyaz, Q.; Sun, W.; Alam, M. "A deep learning approach for network intrusion detection system". In: 9th EAI International Conference on Bio-inspired Information and Communications Technologies (BICT), 2016.. Disponível em: https://eudl.eu/doi/10.4108/eai.3-12-2015.2262516. Acesso em: 13 jul. 2026.

[59] COMPLEMENTAR — GNS3 (emulador gráfico) GNS3 Technologies. "GNS3 — Graphical Network Simulator 3".. Disponível em: https://www.gns3.com/. Acesso em: 13 jul. 2026.

[60] COMPLEMENTAR — PNETLab (emulador multi-vendor) Eve-NG / PNETLab. "PNETLab — Lab is Simple (network emulator platform)".. Disponível em: https://www.pnetlab.com/. Acesso em: 13 jul. 2026.

[61] COMPLEMENTAR — Survey de emuladores/simuladores de rede Engelen, R. V.; et al. "A survey on network simulators, emulators, and testbeds used for research and education". Computer Networks, 2023.. Disponível em: 10.1016/j.comnet.2023.110054URL:https://dl.acm.org/doi/10.1016/j.comnet.2023.110054. Acesso em: 13 jul. 2026.

[62] COMPLEMENTAR — Testbed híbrido SDN (software+hardware) com Mininet Mohammadi, S.; Buzura, S.; et al. "A Hybrid Software and Hardware SDN Simulation Testbed". Sensors, v. 23, n. 1, p. 490, 2023.. Disponível em: 10.3390/s23010490URL:https://www.mdpi.com/1424-8220/23/1/490. Acesso em: 13 jul. 2026.

[63] CORTES, C.; VAPNIK, V. Support-Vector Networks. Machine Learning, v. 20, n. 3, p. 273–297, 1995.. Disponível em: https://doi.org/10.1007/BF00994018URL:https:

//link.springer.com/article/10.1007/BF00994018. Acesso em: 13 jul. 2026.

[64] CUI, T.; LIN, X.; LI, S.; CHEN, M.; YIN, Q.; LI, Q.; XU, K. TrafficLLM: Enhancing Large Language Models for Network Traffic Analysis with Generic Traffic Representation. 2025. arXiv:2504.04222. DOI: https://doi.org/10.48550/arXiv.2504.04222. Disponível em: https://arxiv.org/abs/2504.04222. Acesso em: 13 jul. 2026.

[65] CURTIS, A. R.; MOGUL, J. C.; TOURRILHES, J.; YALAGANDULA, P.; SHARMA, P.; BANERJEE, S. DevoFlow: Scaling Flow Management for High-performance Networks. ACM SIGCOMM 2011, p. 254–265, 2011.. Disponível em: https://doi.org/10.1145/2043164.2018466. Acesso em: 13 jul. 2026.

[66] DETTMERS, T.; PAGNONI, A.; HOLTZMAN, A.; ZETTLEMOYER, L. QLoRA: Efficient Finetuning of Quantized LLMs. Advances in Neural Information Processing Systems (NeurIPS), 2023. arXiv:2305.14314. DOI: https://doi.org/10.48550/arXiv.2305.14314. Disponível em: https://arxiv.org/abs/2305.14314. Acesso em: 13 jul. 2026.

[67] DING, N.; QIN, Y.; YANG, G.; WEI, F.; YANG, Z.; SU, Y. et al. Delta Tuning: A Comprehensive Study of Parameter Efficient Methods for Pre-trained Language Models. 2022. arXiv:2203.06904. DOI: https://doi.org/10.48550/arXiv.2203.06904. Disponível em: https://arxiv.org/abs/2203.06904. Acesso em: 13 jul. 2026.

[68] ESSENCIAL Ali, T.; Kostakos, P. "HuntGPT: Integrating Machine Learning-Based Anomaly Detection and Explainable AI with Large Language Models (LLMs)." arXiv preprint arXiv:2309.16021, 2023.. Disponível em: https://arxiv.org/abs/2309.16021. Acesso em: 13 jul. 2026.

[69] ESSENCIAL Arrieta, A. B.; Díaz-Rodríguez, N.; Del Ser, J.; Bennetot, A.; Tabik, S.; Barbado, A.; et al. "Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI." Information Fusion, vol. 58, pp. 82–115, 2020. DOI:10.1016/j.inffus.2019.10.007.. Disponível em: https://www.sciencedirect.com/science/article/pii/S1566253519308103. Acesso em: 13 jul. 2026.

[70] ESSENCIAL Chen, Y.; et al. "A Survey of Large Language Models for Cyber Threat Detection." Computers & Security, vol. 147, 2024. DOI:10.1016/j.cose.2024.XXXX.. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0167404824003213. Acesso em: 13 jul. 2026.

[71] ESSENCIAL Danilevsky, M.; Qian, K.; Aharonov, R.; Katsis, Y.; Kawas, B.; Sen, P. "A Survey of the State of Explainable AI for Natural Language Processing." Proceedings of AACL-IJCNLP 2020, pp. 447–459. arXiv:2010.00711.. Disponível em: https://arxiv.org/abs/2010.00711|https://aclanthology.org/2020.aacl-main.46/. Acesso em: 13 jul. 2026.

[72] ESSENCIAL Kadavath, S.; Conerly, T.; Askell, A.; Henighan, T.; Drain, D.; Perez, E.; et al. "Language Models (Mostly) Know What They Know." arXiv:2207.05221, 2022.. Disponível em: https://arxiv.org/abs/2207.05221. Acesso em: 13 jul. 2026.

[73] ESSENCIAL Lundberg, S. M.; Lee, S.-I. "A Unified Approach to Interpreting Model Predictions." Advances in Neural Information Processing Systems (NIPS) 2017, pp. 4765–4774.. Disponível em: https://arxiv.org/abs/1705.07874|https://dl.acm.org/doi/10.5555/3295222.3295230. Acesso em: 13 jul. 2026.

[74] ESSENCIAL Neupane, S.; Ables, M.; Chen, W.; D blast, M.; Mittal, S.; Rahimi, S.; et al. "Explainable Intrusion Detection Systems (X-IDS): A Survey of Current Methods, Challenges, and Opportunities." IEEE Access, vol. 10, pp. 112392–112415, 2022.. Disponível em: 10.1109/ACCESS.2022.3215891.(tambÃľmarXiv:2207.06236)URL:https://arxiv.org/abs/2207.06236|https://ieeexplore.ieee.org/document/9927396. Acesso em: 13 jul. 2026.

[75] ESSENCIAL Ribeiro, M. T.; Singh, S.; Guestrin, C. ""Why Should I Trust You?": Explaining the Predictions of Any Classifier." Proceedings of ACM SIGKDD (KDD) 2016, pp. 1135–1144.. Disponível em: https://arxiv.org/abs/1602.04938|https://dl.acm.org/doi/10.1145/2939672.2939778. Acesso em: 13 jul. 2026.

[76] ESSENCIAL Wei, J.; Wang, X.; Schuurmans, D.; Bosma, M.; Ichter, B.; Xia, F.; et al. "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models." Advances in NeurIPS 2022. arXiv:2201.11903.. Disponível em: https://arxiv.org/abs/2201.

11903|https://openreview.net/forum?id=_VjQlMeSB_J. Acesso em: 13 jul. 2026.

[77] ESSENCIAL — AnoLLM (tabular -> texto para LLM em anomalias) Tsai, C.-P.; Teng, G.; Wallis, P.; Ding, W. "AnoLLM: Large Language Models for Tabular Anomaly Detection". In: International Conference on Learning Representations (ICLR), 2025.. Disponível em: https://openreview.net/forum?id=7VkHffT5X2. Acesso em: 13 jul. 2026.

[78] ESSENCIAL — Avaliação estatística do UNSW-NB15 Moustafa, N.; Slay, J. "The evaluation of Network Anomaly Detection Systems: Statistical analysis of the UNSW-NB15 data set and the comparison with the KDD99 data set". Information Security Journal, v. 25, n. 1-3, p. 1-16, 2016.. Disponível em: 10.1080/19393555.2015.1125974URL:https://www.tandfonline.com/doi/abs/10.1080/19393555.2015.1125974. Acesso em: 13 jul. 2026.

[79] ESSENCIAL — Dataset CSE-CIC-IDS2018 (descrição oficial) Canadian Institute for Cybersecurity (CIC) & Communications Security Establishment (CSE). "CSE-CIC-IDS2018 Dataset". University of New Brunswick.. Disponível em: https://www.unb.ca/cic/datasets/ids-2018.html. Acesso em: 13 jul. 2026.

[80] ESSENCIAL — Dataset UNSW-NB15 (descrição oficial / paper fundador) Moustafa, N.; Slay, J. "UNSW-NB15: a comprehensive data set for network intrusion detection systems". In: Military Communications and Information Systems Conference (MilCIS), Canberra, Austrália, 2015. IEEE.. Disponível em: 10.1109/MilCIS.2015.7348942URL:https://ieeexplore.ieee.org/document/7348942. Acesso em: 13 jul. 2026.

[81] ESSENCIAL — Metodologia de geração CIC (base do CSE-CIC-IDS2018) Sharafaldin, I.; Lashkari, A. H.; Ghorbani, A. A. "Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization". In: 4th International Conference on Information Systems Security and Privacy (ICISSP), Portugal, p. 108-116, 2018.. Disponível em: 10.5220/0006639801080116URL:https://www.scitepress.org/papers/2018/66398/66398.pdf. Acesso em: 13 jul. 2026.

[82] ESSENCIAL — Mininet (emulador para SDN) Lantz, B.; Heller, B.; McKeown, N. "A network in a laptop: rapid prototyping

for software-defined networks". In: 9th ACM SIGCOMM Workshop on Hot Topics in Networks (HotNets), 2010.. Disponível em: 10.1145/1868447.1868466URL:https://dl.acm.org/doi/10.1145/1868447.1868466. Acesso em: 13 jul. 2026.

[83] ESSENCIAL — Survey de datasets de NIDS Ring, M.; Wunderlich, S.; Scheuring, D.; Landes, D.; Hotho, A. "A survey of network-based intrusion detection data sets". Computers & Security, v. 86, p. 147-167, 2019.. Disponível em: 10.1016/j.cose.2019.06.005URL:https://www.sciencedirect.com/science/article/abs/pii/S016740481930118X. Acesso em: 13 jul. 2026.

[84] ETSI NFV ISG. GS NFV 002 V1.1.1: Network Functions Virtualisation (NFV); Architectural Framework. ETSI, Outubro de 2013.. Disponível em: https://www.etsi.org/deliver/etsi_gs/NFV/001_099/002/01.01.01_60/gs_NFV002v010101p.pdf. Acesso em: 13 jul. 2026.

[85] ETSI NFV ISG. GS NFV-MAN 001 V1.1.1: Network Functions Virtualisation (NFV); Management and Orchestration. ETSI, Dezembro de 2014.. Disponível em: https://www.etsi.org/deliver/etsi_gs/NFV-MAN/001_099/001/01.01.01_60/gs_NFV-MAN001v010101p.pdf. Acesso em: 13 jul. 2026.

[86] FARNAAZ, N.; MANIMEGALAI, R. Random Forest Modeling for Network Intrusion Detection System (NIDS). Procedia Computer Science, v. 89, p. 213–217, 2016.. Disponível em: https://doi.org/10.1016/j.procs.2016.06.047URL:https://www.sciencedirect.com/science/article/pii/S1877050916311127. Acesso em: 13 jul. 2026.

[87] FEAMSTER, N.; REXFORD, J.; ZEGURA, E. The Road to SDN: An Intellectual History of Programmable Networks. ACM Queue, v. 11, n. 12, p. 20–40, 2013.. Disponível em: https://doi.org/10.1145/2559899.2560327. Acesso em: 13 jul. 2026.

[88] FERNANDES, G.; RODRIGUES, J. J. P. C. et al. A Comprehensive Survey on Network Anomaly Detection. Security and Communication Networks, 2019.. Disponível em: https://doi.org/10.1155/2019/9615476URL:https://onlinelibrary.wiley.com/doi/10.1155/2019/9615476. Acesso em: 13 jul. 2026.

[89] FONDO-FERREIRO, P. et al. Real-time SARIMA-based anomaly detection in operator networks. Computer Networks (Elsevier), 2026.. Disponível em: [NÃČOVERIFICADOâĂŤusarURLabaixo; artigode2026aindaemindexaÃğÃčo]URL:https://www.sciencedirect.com/science/article/pii/S1389128626000824. Acesso em: 13 jul. 2026.

[90] GARCÍA-TEODORO, P.; DÍAZ-VERDEJO, J.; MACIÁ-FERNÁNDEZ, G.; DÍAZ-DÍAZ, E. Anomaly-based Network Intrusion Detection: Techniques, Systems and Challenges. Computers & Security, v. 28, n. 1–2, p. 18–28, 2009.. Disponível em: https://doi.org/10.1016/j.cose.2008.08.003. Acesso em: 13 jul. 2026.

[91] GEMMA TEAM (Google DeepMind). "Gemma: Open Models Based on Gemini Research and Technology". arXiv preprint arXiv:2403.08295, 2024.. Disponível em: https://doi.org/10.48550/arXiv.2403.08295https://arxiv.org/abs/2403.08295. Acesso em: 13 jul. 2026.

[92] GINIGE, Y.; DAHANAYAKA, T.; HUANG, Y.; JOURJON, G.; SENEVIRATNE, S. TrafficGPT: An LLM Approach for Open-Set Encrypted Traffic Classification. Proceedings of the 19th Asian Internet Engineering Conference (AINTEC), 2024.. Disponível em: https://doi.org/10.1145/3674213.3674217URL:https://dl.acm.org/doi/10.1145/3674213.3674217. Acesso em: 13 jul. 2026.

[93] GRATTAFIORI, A.; DUBEY, A.; JAUHRI, A.; PANDEY, A.; KADIAN, A.; AL-DAHLE, A. et al. The Llama 3 Herd of Models. 2024. arXiv:2407.21783.. Disponível em: https://doi.org/10.48550/arXiv.2407.21783URL:https://arxiv.org/abs/2407.21783. Acesso em: 13 jul. 2026.

[94] GRUVER, N.; FINZI, M.; QIU, S.; WILSON, A. G. Large Language Models Are Zero-Shot Time Series Forecasters. NeurIPS, 2023. arXiv:2310.07820.. Disponível em: https://doi.org/10.48550/arXiv.2310.07820URL:https://arxiv.org/abs/2310.07820. Acesso em: 13 jul. 2026.

[95] GUDE, N.; KOPONEN, T.; PETTIT, J.; PFAFF, B.; MCKEOWN, N.; SHENKER, S.; CASADO, M. NOX: Towards an Operating System for Networks. ACM SIGCOMM Computer Communication Review,

v. 38, n. 3, p. 105–110, 2008.. Disponível em: https://doi.org/10.1145/1384609.1384625. Acesso em: 13 jul. 2026.

[96] HAN, B.; GOPALAKRISHNAN, V.; JI, L.; LEE, S. Network Function Virtualization: Challenges and Opportunities for Innovations. IEEE Communications Magazine, v. 53, n. 2, p. 90–97, 2015.. Disponível em: https://doi.org/10.1109/MCOM.2015.7045396. Acesso em: 13 jul. 2026.

[97] HAN, Z.; GAO, C.; LIU, J.; ZHANG, J.; ZHANG, S. Q. Parameter-Efficient Fine-Tuning for Large Models: A Comprehensive Survey. 2024. arXiv:2403.14608.. Disponível em: https://doi.org/10.48550/arXiv.2403.14608URL:https://arxiv.org/abs/2403.14608. Acesso em: 13 jul. 2026.

[98] HANG, Ching-Nam; YU, Pei-Duo; MORABITO, Roberto; TAN, Chee-Wei. "Large Language Models Meet Next-Generation Networking Technologies: A Review". Future Internet, v. 16, n. 10, p. 365, 2024.. Disponível em: https://doi.org/10.3390/fi16100365https://www.mdpi.com/1999-5903/16/10/365. Acesso em: 13 jul. 2026.

[99] HE, J.; ZHOU, C.; MA, X.; BERG-KIRKPATRICK, T.; NEUBIG, G. Towards a Unified View of Parameter-Efficient Transfer Learning. ICLR (Spotlight), 2022. arXiv:2110.04366. DOI: https://doi.org/10.48550/arXiv.2110.04366. Disponível em: https://arxiv.org/abs/2110.04366. Acesso em: 13 jul. 2026.

[100] HEGSELMANN, S.; BUENDIA, A.; LANG, H.; AGRAWAL, M.; JIANG, X.; SONTAG, D. TabLLM: Few-shot Classification of Tabular Data with Large Language Models. AISTATS, 2023. arXiv:2210.10723. DOI: https://doi.org/10.48550/arXiv.2210.10723. Disponível em: https://arxiv.org/abs/2210.10723. Acesso em: 13 jul. 2026.

[101] HELLER, B.; SHERWOOD, R.; MCKEOWN, N. The Controller Placement Problem. ACM SIGCOMM HotSDN '12, p. 7–12, 2012.. Disponível em: https://doi.org/10.1145/2342441.2342444. Acesso em: 13 jul. 2026.

[102] HODO, E.; BELLEKENS, X.; HAMILTON, A.; DUBOULIL, C.; PHAM, Q. N. Threat Analysis of IoT Networks Using Artificial Neural Network Intrusion Detection System. In: Int. Symp. on Networks, Computers and Communications (ISNCC), IEEE, 2017.. Disponível

em: https://doi.org/10.1109/ISNCC.2017.8005728URL:https://ieeexplore.ieee.org/document/8005728/. Acesso em: 13 jul. 2026.

[103] HONG, J.; et al. "A Comprehensive Survey on LLM-Based Network Management and Orchestration". International Journal of Network Management (Wiley), 2025.. Disponível em: https://doi.org/10.1002/nem.70029https://onlinelibrary.wiley.com/doi/abs/10.1002/nem.70029. Acesso em: 13 jul. 2026.

[104] HOSSAIN, M. K.; et al. "NetIntent: Leveraging Large Language Models for End-to-End Intent-Based SDN Automation". IEEE Transactions on Network and Service Management, 2025 (arXiv:2507.14398).. Disponível em: https://doi.org/10.1109/TNSM.2025.11293797https://arxiv.org/abs/2507.14398. Acesso em: 13 jul. 2026.

[105] HOULSBY, N.; GIURGIU, A.; JASTRZEBSKI, S.; MORRONE, B.; DE LAROUSSILHE, Q.; GESMUNDO, A.; ATTARIYAN, M.; GELLY, S. Parameter-Efficient Transfer Learning for NLP. ICML, 2019. arXiv:1902.00751. DOI: https://doi.org/10.48550/arXiv.1902.00751. Disponível em: https://arxiv.org/abs/1902.00751. Acesso em: 13 jul. 2026.

[106] HU, E. J.; SHEN, Y.; WALLIS, P.; ALLEN-ZHU, Z.; LI, Y.; WANG, S.; WANG, L.; CHEN, W. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685, 2021. DOI: https://doi.org/10.48550/arXiv.2106.09685. Disponível em: https://arxiv.org/abs/2106.09685. Acesso em: 13 jul. 2026.

[107] HU, Edward J.; SHEN, Yelong; WALLIS, Phillip; et al. "LoRA: Low-Rank Adaptation of Large Language Models". arXiv preprint arXiv:2106.09685, 2021 (ICLR 2022).. Disponível em: https://doi.org/10.48550/arXiv.2106.09685https://arxiv.org/abs/2106.09685. Acesso em: 13 jul. 2026.

[108] HU, Z.; WANG, L.; LAN, Y.; XU, W.; LIM, E.-P.; BING, L.; XU, X.; PORIA, S.; LEE, R. K.-W. LLM-Adapters: An Adapter Family for Parameter-Efficient Fine-Tuning of Large Language Models. EMNLP, 2023. arXiv:2304.01933.. Disponível em: https://doi.org/10.48550/arXiv.2304.01933URL:https://arxiv.org/abs/2304.01933. Acesso em: 13 jul. 2026.

[109] HUANG, Yong; et al. "Large Language Models for Networking: Applications, Enabling Techniques, and Challenges". IEEE Network, v. 39, n. 1, p. 235–242, 2025 (Early Access 2024).. Disponível em: https://doi.org/10.1109/MNET.2024.3435752https://ieeexplore.ieee.org/document/10777581/(viaCrossRef). Acesso em: 13 jul. 2026.

[110] JAIN, S.; KUMAR, A.; MANDAL, S.; ONG, J.; PIETZ, L.; et al. B4: Experience with a Globally-Deployed Software Defined WAN. ACM SIGCOMM 2013, p. 3–14, 2013.. Disponível em: https://doi.org/10.1145/2534169.2486019. Acesso em: 13 jul. 2026.

[111] JIANG, Albert Q.; SABLAYROLLES, Alexandre; MENSCH, Arthur; et al. (Mistral AI). "Mistral 7B". arXiv preprint arXiv:2310.06825, 2023.. Disponível em: https://doi.org/10.48550/arXiv.2310.06825https://arxiv.org/abs/2310.06825. Acesso em: 13 jul. 2026.

[112] JIANG, A. Q.; SABLAYROLLES, A.; MENSCH, A.; BAMFORD, C.; CHAPLOT, D. S. et al. Mistral 7B. 2023. arXiv:2310.06825. DOI: https://doi.org/10.48550/arXiv.2310.06825. Disponível em: https://arxiv.org/abs/2310.06825. Acesso em: 13 jul. 2026.

[113] JIANG, J.-P.; LIU, S.-Y.; CAI, H.-R.; ZHOU, Q.; YE, H.-J. Representation Learning for Tabular Data: A Comprehensive Survey. 2025. arXiv:2504.16109.. Disponível em: https://doi.org/10.48550/arXiv.2504.16109URL:https://arxiv.org/abs/2504.16109. Acesso em: 13 jul. 2026.

[114] KOPONEN, T.; AMIDON, K.; BALLAND, P.; CASADO, M.; CHANDA, A.; FULTON, B.; et al. Network Virtualization in Multi-tenant Datacenters. USENIX NSDI '14, p. 203–216, 2014.. Disponível em: https://www.usenix.org/system/files/conference/nsdi14/nsdi14-paper-koponen.pdf. Acesso em: 13 jul. 2026.

[115] KREUTZ, D.; RAMOS, F. M. V.; VERISSIMO, P. E.; ROTHENBERG, C. E.; AZODOLMOLKY, S.; UHLIG, S. Software-Defined Networking: A Comprehensive Survey. Proceedings of the IEEE, v. 103, n. 1, p. 14–76, 2015.. Disponível em: https://doi.org/10.1109/JPROC.2014.2371999(versÃčopreprint:https://arxiv.org/abs/1406.0440). Acesso em: 13 jul. 2026.

[116] KUNDU, A.; LIM, F.; CHEW, A.; WYNTER, L.; CHONG, P.; LEE, R. D. Efficiently Distilling LLMs for Edge Applications. NAACL (Industry Track), 2024. arXiv:2404.01353. DOI:

https://doi.org/10.48550/arXiv.2404.01353. Disponível em: https://arxiv.org/abs/2404.01353. Acesso em: 13 jul. 2026.

[117] LAGHRISSI, A.; TALEB, T. A Survey on the Placement of Virtual Resources and Virtual Network Functions. IEEE Communications Surveys & Tutorials, v. 21, n. 2, p. 1409–1434, 2019.. Disponível em: https://doi.org/10.1109/COMST.2018.2869440. Acesso em: 13 jul. 2026.

[118] LAKHINA, A.; CROVELLA, M.; DIOT, C. Diagnosing Network-Wide Traffic Anomalies. In: Proc. of ACM SIGCOMM 2004, p. 219–230, 2004.. Disponível em: https://doi.org/10.1145/1030194.1015492URL:https://dl.acm.org/doi/10.1145/1030194.1015492. Acesso em: 13 jul. 2026.

[119] LANTZ, B.;HELLER, B.; MCKEOWN, N. A Network in a Laptop: Rapid Prototyping for Software-Defined Networks. ACM SIGCOMM HotNets-IX, 2010.. Disponível em: https://conferences.sigcomm.org/hotnets/2010/papers/a19-lantz.pdf. Acesso em: 13 jul. 2026.

[120] LATIF, Z.; SHARIF, K.; LI, F.; KARIM, M. M.; BELGHITI, M. A.; SANGEEN, A. A Machine Learning-Based Anomaly Prediction Service for Software-Defined Networks. Sensors, v. 22, n. 21, artigo 8434, 2022.. Disponível em: https://doi.org/10.3390/s22218434. Acesso em: 13 jul. 2026.

[121] LEE, C. B.; CARDENAS, A. A.; ET AL. Detection and Characterization of Port Scan Attacks. (Projeto, UC San Diego.). Disponível em: https://cseweb.ucsd.edu/~clbailey/PortScans.pdf. Acesso em: 13 jul. 2026.

[122] LEIVADEAS, A.; FALKNER, M. A Survey on Intent-Based Networking. IEEE Communications Surveys & Tutorials, v. 25, n. 1, p. 625–655, 1º trim. 2023. (Publicado online 2022; DOI: 10.1109/COMST.2022.3215919.). Disponível em: https://doi.org/10.1109/COMST.2022.3215919. Acesso em: 13 jul. 2026.

[123] LESTER, B.; AL-RFOU, R.; CONSTANT, N. The Power of Scale for Parameter-Efficient Prompt Tuning. EMNLP, 2021. arXiv:2104.08691.. Disponível em: https://doi.org/10.48550/arXiv.2104.08691URL:https://arxiv.org/abs/2104.08691. Acesso em: 13 jul. 2026.

[124] LI, W.; MENG, W.; KWOK, L.-F. A Survey on OpenFlow-based Software Defined Networks: Security Challenges and Countermeasures.

Journal of Network and Computer Applications, v. 68, p. 126–139, 2016.. Disponível em: https://doi.org/10.1016/j.jnca.2016.04.011. Acesso em: 13 jul. 2026.

[125] LI, X. L.; LIANG, P. Prefix-Tuning: Optimizing Continuous Prompts for Generation. ACL-IJCNLP, 2021. DOI: https://doi.org/10.18653/v1/2021.acl-long.353. Disponível em: https://aclanthology.org/2021.acl-long.353/. Acesso em: 13 jul. 2026.

[126] LIU, X.; JI, K.; FU, Y.; TAM, W. L.; DU, Z.; YANG, Z.; TANG, J. P-Tuning v2: Prompt Tuning Can Be Comparable to Fine-tuning Universally Across Scales and Tasks. ACL, 2022. arXiv:2110.07602. DOI: https://doi.org/10.48550/arXiv.2110.07602. Disponível em: https://arxiv.org/abs/2110.07602. Acesso em: 13 jul. 2026.

[127] LIU, H.; TAM, D.; MUQEETH, M.; MOHTA, J.; HUANG, T.; BANSAL, M.; RAFFEL, C. Few-Shot Parameter-Efficient Fine-Tuning is Better and Cheaper than In-Context Learning. NeurIPS, 2022. arXiv:2205.05638. DOI: https://doi.org/10.48550/arXiv.2205.05638. Disponível em: https://arxiv.org/abs/2205.05638. Acesso em: 13 jul. 2026.

[128] LIU, Chang; XIE, Xiaohui; ZHANG, Xinggong; CUI, Yong. "Large Language Models for Networking: Workflow, Advances and Challenges". IEEE Network, v. 39, n. 5, p. 235–242, 2025 (arXiv:2404.12901, 2024).. Disponível em: https://doi.org/10.48550/arXiv.2404.12901https://arxiv.org/abs/2404.12901https://ieeexplore.ieee.org/document/10777581/. Acesso em: 13 jul. 2026.

[129] LIU, S.-Y.; WANG, C.-Y.; YIN, H.; MOLCHANOV, P.; WANG, Y.-C. F.; CHENG, K.-T.; CHEN, M.-H. DoRA: Weight-Decomposed Low-Rank Adaptation. ICML (Oral), 2024. arXiv:2402.09353. DOI: https://doi.org/10.48550/arXiv.2402.09353. Disponível em: https://arxiv.org/abs/2402.09353. Acesso em: 13 jul. 2026.

[130] LIU, Fan; BEHROOZ, Fatemeh; et al. "Large Language Models for Computer Networking Operations and Management: A Survey on Applications, Key Techniques, and Opportunities". Computer Networks, v. 264, 2025, p. 111614.. Disponível em: https://doi.org/10.1016/j.comnet.2025.111614https://www.

techrxiv.org/doi/10.36227/techrxiv.173386065.57486944. Acesso em: 13 jul. 2026.

[131] LIU, H.; et al. "The Dual Role of Large Language Models in Network Security: Threat Detection and Attack Generation". Workshop WISEML, 2025.. Disponível em: https://cs.ou.edu/~shangqing/res/26wiseml/25lxz-wiseml.pdf. Acesso em: 13 jul. 2026.

[132] McKEOWN, N.; ANDERSON, T.; BALAKRISHNAN, H.; PARULKAR, G.; PETERSON, L.; REXFORD, J.; SHENKER, S.; TURNER, J. OpenFlow: Enabling Innovation in Campus Networks. ACM SIGCOMM Computer Communication Review, v. 38, n. 2, p. 69–74, 2008.. Disponível em: https://doi.org/10.1145/1355734.1355746. Acesso em: 13 jul. 2026.

[133] MEDVED, J.; VARGA, R.; TKACIK, A.; GRAY, K. OpenDaylight: Towards a Model-Driven SDN Controller Architecture. ACM SIGCOMM HotSDN '14, p. 1–6, 2014.. Disponível em: https://doi.org/10.1145/2620728.2620733. Acesso em: 13 jul. 2026.

[134] MENG, X.; LIN, C.; WANG, Y.; ZHANG, Y. NetGPT: Generative Pretrained Transformer for Network Traffic. 2023 (rev. 2025). arXiv:2304.09513.. Disponível em: https://doi.org/10.48550/arXiv.2304.09513URL:https://arxiv.org/abs/2304.09513. Acesso em: 13 jul. 2026.

[135] MIJUMBI, R.; SERRAT, J.; GORRICHO, J.-L.; BOUTEN, N.; DE TURCK, F.; BOUTABA, R. Network Function Virtualization: State-of-the-Art and Research Challenges. IEEE Communications Magazine, v. 53, n. 2, p. 216–228, 2015.. Disponível em: https://doi.org/10.1109/MCOM.2015.7243304. Acesso em: 13 jul. 2026.

[136] MIJUMBI, R.; SERRAT, J.; GORRICHO, J.-L.; BOUTEN, N.; DE TURCK, F.; BOUTABA, R. Network Function Virtualization: State-of-the-Art and Research Challenges. IEEE Communications Surveys & Tutorials, v. 18, n. 1, p. 236–262, 2016. (Versão estendida; preprint: https://arxiv.org/abs/ 1509.07675). Disponível em: https://doi.org/10.1109/COMST.2015.2477041. Acesso em: 13 jul. 2026.

[137] MOAYEDI, H. Z.; AMINI, M. ARIMA Model for Network Traffic Prediction and Anomaly Detection. In: Proc.

of the 4th International Conference on Information Technology (ICIT 2008), IEEE, 2008.. Disponível em: https://doi.org/10.1109/ICIT.2008.22(viaIEEEXplore)URL:https://ieeexplore.ieee.org/document/4631947/. Acesso em: 13 jul. 2026.

[138] MORALES, F.; RUIZ, M.; CONTRERAS, L. M.; FERRARIS, G.; STAVDAS, A.; CUGINI, F.; VELASCO, L. Virtual Network Topology Adaptability Based on Data Analytics for Traffic Prediction. IEEE/OSA Journal of Optical Communications and Networking, v. 9, n. 1, p. A35–A45, 2017.. Disponível em: https://doi.org/10.1364/JOCN.9.000A35. Acesso em: 13 jul. 2026.

[139] MOUSTAFA, N.; SLAY, J. UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems (UNSW-NB15 Network Data Set). In: Military Communications and Information Systems Conference (MilCIS), IEEE, 2015.. Disponível em: https://doi.org/10.1109/MILCIS.2015.7348942URL:https://ieeexplore.ieee.org/document/7348942. Acesso em: 13 jul. 2026.

[140] MUKKAMALA, S.; SUNG, A. H.; RIBEIRO, B. Intrusion Detection Systems Using Adaptive Models and Multivariate Adaptive Regression Splines (MARS) and Support Vector Machines. In: Proc. of the IEEE International Joint Conference on Neural Networks (IJCNN), 2003.. Disponível em: https://doi.org/10.1109/IJCNN.2003.1223399(viaIEEEXplore)URL:https://ieeexplore.ieee.org/document/4370710/(rel.CH-SVM). Acesso em: 13 jul. 2026.

[141] NEGANDHI, P.; TRIVEDI, Y. Intrusion Detection System Using Random Forest on the NSL-KDD Dataset. In: Proc. of Int. Conf. on Computing, Analytics and Security Trends (CAST), 2016.. Disponível em: https://www.researchgate.net/publication/335718695_Intrusion_Detection_System_Using_Random_Forest_on_the_NSL-KDD_Dataset. Acesso em: 13 jul. 2026.

[142] NOXRepo. POX: The POX network software platform (controlador OpenFlow em Python). Projeto open-source (sucessor educacional do NOX).. Disponível em: https://github.com/noxrepo/pox|docs:https://noxrepo.github.io/pox-doc/html/. Acesso em: 13 jul. 2026.

[143] NTT Laboratories. Ryu SDN Framework — Open-source SDN Platform Software. NTT Technical Review, v. 12, n. 8, 2014.. Disponível em: https://www.ntt-review.jp/archive/ntttechnical.php?contents=ntr201408fa4.html. Acesso em: 13 jul. 2026.

[144] Open Networking Foundation (ONF). OpenFlow Switch Specification, Version 1.0.0 (ONF TS-001), Dezembro de 2009.. Disponível em: https://opennetworking.org/wp-content/uploads/2013/04/openflow-spec-v1.0.0.pdf. Acesso em: 13 jul. 2026.

[145] OUYANG, Long; WU, Jeffrey; JIANG, Xu; et al. "Training Language Models to Follow Instructions with Human Feedback (InstructGPT)". arXiv preprint arXiv:2203.02155, 2022 (NeurIPS).. Disponível em: https://doi.org/10.48550/arXiv.2203.02155https://arxiv.org/abs/2203.02155. Acesso em: 13 jul. 2026.

[146] PENA, G.; ASSIS, K. Anomaly Detection Using Forecasting Methods ARIMA and SARIMA. (Trabalho acadêmico, disponível via Semantic Scholar.). Disponível em: https://www.semanticscholar.org/paper/Anomaly-Detection-Using-Forecasting-Methods-ARIMA-Pena-Assis/1ede5a06149233fc02f38a7a7fe76771bb94e6ed. Acesso em: 13 jul. 2026.

[147] PENG, L. et al. PTU: Pre-Trained Model for Network Traffic Understanding. IEEE 32nd International Conference on Network Protocols (ICNP), 2024.. Disponível em: https://doi.org/10.1109/icnp61940.2024.10858503URL:https://doi.org/10.1109/icnp61940.2024.10858503. Acesso em: 13 jul. 2026.

[148] PFAFF, B.; PETTIT, J.; KOPONEN, T.; AMIDON, K.; CASADO, M.; SHENKER, S. The Design and Implementation of Open vSwitch. USENIX NSDI '15, p. 117–130, 2015.. Disponível em: https://www.usenix.org/conference/nsdi15/technical-sessions/presentation/pfaff. Acesso em: 13 jul. 2026.

[149] PORRAS, P.; SHIN, S.; YEGNESWARAN, V.; FONG, M.; TYSON, M.; GU, G. A Security Enforcement Kernel for OpenFlow Networks. ISOC NDSS '12, 2012.. Disponível em: https://www.csl.sri.com/~vinod/papers/fortnox.pdf. Acesso em: 13 jul. 2026.

[150] RECOMENDADO "LLMs in the SOC: An Empirical Study of Human-AI Collaboration." arXiv:2508.18947, 2025.. Disponível em: https://arxiv.org/html/2508.18947v1. Acesso em: 13 jul. 2026.

[151] RECOMENDADO Adadi, A.; Berrada, M. "Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)." IEEE Access, vol. 6, pp. 52138–52160, 2018.. Disponível em: 10.1109/ACCESS.2018.2870052.URL:https://ieeexplore.ieee.org/document/8477178. Acesso em: 13 jul. 2026.

[152] RECOMENDADO Amarasinghe, K.; Kenney, K.; Manic, M. "Toward Explainable Deep Neural Network Based Anomaly Detection." 11th IEEE International Conference on Human System Interaction (HSI), 2018, pp. 311–317. DOI:10.1109/HSI.2018.8430788.. Disponível em: https://par.nsf.gov/servlets/purl/10084128. Acesso em: 13 jul. 2026.

[153] RECOMENDADO Dang, Y.; Huang, K.; et al. "Explainable and Interpretable Multimodal Large Language Models: A Comprehensive Survey." arXiv:2412.02104, 2024.. Disponível em: https://arxiv.org/abs/2412.02104. Acesso em: 13 jul. 2026.

[154] RECOMENDADO Gaspar, D.; Domingues, P.; Teixeira, R. "Explainable AI for Intrusion Detection Systems: LIME and SHAP Applicability on Multi-Layer Perceptron." IEEE Access, vol. 12, pp. 89749–89769, 2024. DOI:10.1109/ACCESS.2024.3418001.. Disponível em: https://ieeexplore.ieee.org/document/10440604. Acesso em: 13 jul. 2026.

[155] RECOMENDADO Gilpin, L. H.; Bau, D.; Yuan, B. Z.; Bajwa, A.; Specter, M.; Kagal, L. "Explaining Explanations: An Overview of Interpretability of Machine Learning." IEEE DSAA 2018, pp. 80–89. DOI:10.1109/DSAA.2018.00018.. Disponível em: https://ieeexplore.ieee.org/document/8517281. Acesso em: 13 jul. 2026.

[156] RECOMENDADO Guidotti, R.; Monreale, A.; Ruggieri, S.; Turini, F.; Giannotti, F.; Pedreschi, D. "A Survey of Methods for Explaining Black Box Models." ACM Computing Surveys, vol. 51, no. 5, art. 93, 2018. DOI:10.1145/3236009.. Disponível em: https://dl.acm.org/doi/10.1145/3236009. Acesso em: 13 jul. 2026.

[157] RECOMENDADO Guo, C.; Pleiss, G.; Sun, Y.; Weinberger, K. Q. "On Calibration of Modern Neural Networks." Proceedings of ICML 2017, PMLR 70, pp. 1321–1330.. Disponível

em: https://arxiv.org/abs/1706.04599|https://proceedings.mlr.press/v70/guo17a.html. Acesso em: 13 jul. 2026.

[158] RECOMENDADO Habibzadeh, A.; et al. "Large Language Models for Security Operations Centers: A Comprehensive Survey." Journal of Electrical and Computer Engineering, Hindawi/Wiley, 2026. DOI:10.1155/jece/3383674.. Disponível em: https://onlinelibrary.wiley.com/doi/10.1155/jece/3383674. Acesso em: 13 jul. 2026.

[159] RECOMENDADO Kenney, K.; Manic, M. "Robust Network Intrusion Detection Through Explainable Artificial Intelligence (XAI)." IEEE Networking Letters, vol. 4, no. 3, pp. 167–171, 2022. DOI:10.1109/LNET.2022.3187333.. Disponível em: https://ieeexplore.ieee.org/document/9807332. Acesso em: 13 jul. 2026.

[160] RECOMENDADO Lin, S.; Hilton, J.; Evans, O. "Teaching Models to Express Their Uncertainty in Words." Transactions on Machine Learning Research (TMLR), 2022. arXiv:2205.14334.. Disponível em: https://arxiv.org/abs/2205.14334. Acesso em: 13 jul. 2026.

[161] RECOMENDADO Molnar, C. "Interpretable Machine Learning: A Guide for Making Black Box Models Explainable." 2.ª ed., 2022 (livro aberto, leanpub / christophm.github.io).. Disponível em: https://christophm.github.io/interpretable-ml-book/. Acesso em: 13 jul. 2026.

[162] RECOMENDADO Montavon, G.; Binder, A.; Lapuschkin, S.; Samek, W.; Müller, K.-R. "Methods for Interpreting and Understanding Deep Neural Networks." Proceedings of IEEE, vol. 106, no. 9, pp. 1565–1580, 2018. DOI:10.1109/JPROC.2018.2858358.. Disponível em: https://ieeexplore.ieee.org/document/8528688. Acesso em: 13 jul. 2026.

[163] RECOMENDADO Rjoub, G.; Bentahar, J.; Wahab, O. A.; Bataineh, I. "A Survey on Explainable Artificial Intelligence for Cybersecurity." IEEE Transactions on Network and Service Management, vol. 20, no. 4, pp. 5115–5140, 2023.. Disponível em: 10.1109/TNSM.2023.3282740.(tambÃľmarXiv:2303.12942)URL: https://arxiv.org/abs/2303.12942. Acesso em: 13 jul. 2026.

[164] RECOMENDADO Samek, W.; Montavon, G.; Vedaldi, A.; Hansen, L. K.; Müller, K.-R. (Eds.). "Explainable AI: Interpreting, Explaining and Visualizing Deep Learning." Springer LNCS 11700,

2019. DOI:10.1007/978-3-030-28954-6.. Disponível em: https://link.springer.com/book/10.1007/978-3-030-28954-6. Acesso em: 13 jul. 2026.

[165] RECOMENDADO Sarker, I. H. "Explainable AI for Cybersecurity Automation, Intelligence and Trustworthiness in Digital Twin: Methods, Taxonomy, Challenges and Prospects." ICT Express, vol. 10, no. 4, pp. 935–958, 2024. DOI:10.1016/j.icte.2024.05.009.. Disponível em: https://www.sciencedirect.com/science/article/pii/S2405959524000572. Acesso em: 13 jul. 2026.

[166] RECOMENDADO Yamin, M. M.; et al. "Applications of LLMs for Generating Cyber Security Testbeds and Threat Analysis." IEEE Access, 2024. DOI:10.1109/ACCESS.2024.XXXX.. Disponível em: https://ieeexplore.ieee.org/document/10695083. Acesso em: 13 jul. 2026.

[167] RECOMENDADO Zhang, J.; et al. "When LLMs Meet Cybersecurity: A Systematic Literature Review." Cybersecurity (Springer), vol. 8, art. 13, 2025. DOI:10.1186/s42400-025-00361-w.. Disponível em: https://link.springer.com/article/10.1186/s42400-025-00361-w. Acesso em: 13 jul. 2026.

[168] RECOMENDADO Zhu, C.; Xu, B.; Wang, Q.; Zhang, Y.; Mao, Z. "On the Calibration of Large Language Models and Alignment." Findings of EMNLP 2023, pp. 6629–6644. arXiv:2311.13240.. Disponível em: https://arxiv.org/abs/2311.13240|https://aclanthology.org/2023.findings-emnlp.654/. Acesso em: 13 jul. 2026.

[169] RECOMENDADO — Análise do KDD Cup 99 / NSL-KDD (linha de base histórica) Tavallaee, M.; Bagheri, E.; Lu, W.; Ghorbani, A. A. "A detailed analysis of the KDD CUP 99 data set". In: IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA), 2009.. Disponível em: 10.1109/CISDA.2009.5356528URL:https://www.ee.torontomu.ca/~bagheri/papers/cisda.pdf. Acesso em: 13 jul. 2026.

[170] RECOMENDADO — Augmentation GAN para classes minoritárias em rede Kang, F.; et al. "A Class Imbalance Data Augmentation Method for Network Intrusion Detection Based on M2M-VAEGAN". Electronics, v. 14, n. 11, 2025.. Disponível

em: 10.3390/electronics14112103URL:https://www.mdpi.com/2079-9292/14/11/2103. Acesso em: 13 jul. 2026.

[171] RECOMENDADO — Data augmentation em IoT (desbalanceamento) Zhang, Y.; Liu, Q. "On IoT intrusion detection based on data augmentation for enhancing learning on unbalanced samples". Future Generation Computer Systems, v. 133, p. 145-155, 2022.. Disponível em: 10.1016/j.future.2022.03.007URL:https://www.sciencedirect.com/science/article/abs/pii/S0167739X22000826. Acesso em: 13 jul. 2026.

[172] RECOMENDADO — Dataset BoT-IoT (IoT sintético) Koroniotis, N.; Moustafa, N.; Sitnikova, E.; Turnbull, B. "Towards the development of realistic botnet dataset in the Internet of Things for network forensic analytics: Bot-IoT dataset". Future Generation Computer Systems, v. 100, p. 779-796, 2019.. Disponível em: 10.1016/j.future.2019.05.041URL:https://www.sciencedirect.com/science/article/pii/S0167739X18327687. Acesso em: 13 jul. 2026.

[173] RECOMENDADO — Dataset InSDN (SDN intrusion) Elsayed, M. S.; Le-Khac, N.-A.; Dev, S.; Jurcut, A. D. "InSDN: A Novel SDN Intrusion Dataset". IEEE Access, v. 8, p. 165263-165284, 2020.. Disponível em: 10.1109/ACCESS.2020.3022633URL:https://ieeexplore.ieee.org/document/9187858. Acesso em: 13 jul. 2026.

[174] RECOMENDADO — Detecção zero-shot de anomalias tabulares com LLMs Li, A.; Wang, S.; Wang, G.; Zhong, S. "Anomaly Detection of Tabular Data Using LLMs". arXiv preprint, 2024. arXiv: 2406.16308. Disponível em: https://arxiv.org/abs/2406.16308. Acesso em: 13 jul. 2026.

[175] RECOMENDADO — Ferramenta CICFlowMeter (geração de features) Canadian Institute for Cybersecurity. "CICFlowMeter — Network Traffic Flow Generator and Analyzer".. Disponível em: https://www.unb.ca/cic/research/applications.html. Acesso em: 13 jul. 2026.

[176] RECOMENDADO — Geração de dados DDoS em SDN (Mininet+Ryu) Gayantha, N. "Customizable DDoS attack data generation in SDN environment using Mininet and Ryu controller". Robert Gordon University, 2025.. Disponível em: https://rgu-repository.worktribe.com/OutputFile/2801592. Acesso em: 13 jul. 2026.

[177] RECOMENDADO — Geração sintética e privacy-preserving de traces Aceto, G.; Ciuonzo, D.; Montieri, A.; Persico, V.; Pescapè, A. "Synthetic and privacy-preserving traffic trace generation using generative AI models for training Network Intrusion Detection Systems". Journal of Network and Computer Applications, 2024.. Disponível em: 10.1016/j.jnca.2024.103926URL:https://dl.acm.org/doi/10.1016/j.jnca.2024.103926. Acesso em: 13 jul. 2026.

[178] RECOMENDADO — NetFlow datasets (alternativa tabular) Sarhan, M.; Layeghy, S.; Moustafa, N.; Portmann, M. "NetFlow datasets for machine learning-based network intrusion detection systems". In: 15th EAI International Conference on Wireless Internet (WiCON), 2020. arXiv: 2011.09144. Disponível em: https://arxiv.org/abs/2011.09144. Acesso em: 13 jul. 2026.

[179] RECOMENDADO — Review de datasets de IDS Thakkar, A.; Lohiya, R. "A review of the advancement in intrusion detection datasets". Procedia Computer Science, v. 167, p. 636-645, 2020.. Disponível em: 10.1016/j.procs.2020.03.330URL:https://www.sciencedirect.com/science/article/pii/S1877050920307961. Acesso em: 13 jul. 2026.

[180] RECOMENDADO — Review de IDS por ML/DL em IoT Asharf, J.; Moustafa, N.; Khurshid, H.; Choo, K.-K. R. "A Review of Intrusion Detection Systems Using Machine and Deep Learning in Internet of Things: Challenges, Solutions and Future Directions". Electronics, v. 9, n. 7, p. 1177, 2020.. Disponível em: 10.3390/electronics9071177URL:https://www.mdpi.com/2079-9292/9/7/1177. Acesso em: 13 jul. 2026.

[181] RECOMENDADO — Survey de geração sintética de tráfego de rede "Synthetic Network Traffic Data Generation: A Comparative Analysis". arXiv preprint, 2024. arXiv: 2410.16326. Disponível em: https://arxiv.org/abs/2410.16326. Acesso em: 13 jul. 2026.

[182] RECOMENDADO — Survey LLMs em dados tabulares Fang, X.; Xu, W.; Tan, Z.; Liu, J.; Huang, Q.; et al. "Large Language Models on Tabular Data: A Survey". arXiv preprint, 2024. arXiv: 2402.17944. Disponível em: https://arxiv.org/abs/2402.17944. Acesso em: 13 jul. 2026.

[183] ROBERTS, S. W. Control Chart Tests Based on Geometric Moving Averages. Technometrics, v. 1, n. 3, p. 239–250, 1959..

Disponível em: https://www.stat.cmu.edu/technometrics/90-00/vol-42-01/v4201097.pdf. Acesso em: 13 jul. 2026.

[184] RODRIGUES, João Pedro Santos. **Detecção e Mitigação Inteligente de Anomalias em Redes Definidas por Software com Grandes Modelos de Linguagem Open Source**. Januária, MG: [s.n.], 2026. Projeto de Pesquisa (Edital nº 26/2026).

[185] SCHUMMER, P. et al. Machine Learning-Based Network Anomaly Detection. Applied Sciences (MDPI), v. 14, n. 4, p. 143, 2024.. Disponível em: https://doi.org/10.3390/app14041043(OpenAccess)URL: https://www.mdpi.com/2673-2688/5/4/143. Acesso em: 13 jul. 2026.

[186] SCHWARTZ, E.; CHOSHEN, L.; SHTOK, J.; DOVEH, S.; KARLINSKY, L.; ARBELLE, A. NumeroLogic: Number Encoding for Enhanced LLMs' Numerical Reasoning. EMNLP, 2024. arXiv:2404.00459. DOI: https://doi.org/10.48550/arXiv.2404.00459. Disponível em: https://arxiv.org/abs/2404.00459. Acesso em: 13 jul. 2026.

[187] SCHÖLKOPF, B.; PLATT, J.; SHAWE-TAYLOR, J.; SMOLA, A.; WILLIAMSON, R. Estimating the Support of a High-Dimensional Distribution. Neural Computation, v. 13, n. 7, p. 1443–1471, 2001.. Disponível em: https://doi.org/10.1162/089976601750264965URL:https://dl.acm.org/doi/10.1162/089976601750264965. Acesso em: 13 jul. 2026.

[188] SHARAFALDIN, I.; LASHKARI, A. H.; GHORBANI, A. A. Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization. In: 4th Int. Conf. on Information Systems Security and Privacy (ICISSP), 2018.. Disponível em: https://doi.org/10.5220/0006639801080116URL:https://www.scitepress.org/papers/2018/66398/66398.pdf(OpenAccess). Acesso em: 13 jul. 2026.

[189] SHEHAB, R. et al. Improving Port Scan Cybersecurity Risks Detection using Feature Selection and Machine Learning. JATIT, v. 102, n. 16, 2024.. Disponível em: https://www.jatit.org/volumes/Vol102No16/9Vol102No16.pdf. Acesso em: 13 jul. 2026.

[190] SHERWOOD, R.; GIBB, G.; YAP, K.-K.; McKEOWN, N.; et al. FlowVisor: A Network Virtualization Layer. OpenFlow Switch

Consortium, Tech. Rep., 2009; apresentado em contexto de OSDI '10.. Disponível em: https://mediatum.ub.tum.de/doc/1656940/dkm9djytuntzjem41xt8fz2s6.main.pdf(referÃłnciatÃľcnica);projeto:https://github.com/OPENNETWORKING. Acesso em: 13 jul. 2026.

[191] SLAMANIG, G.; CORTI, F.; SAUKH, O. From LLMs to Edge: Parameter-Efficient Fine-Tuning on Edge Devices. 2025. arXiv:2507.23536.. Disponível em: https://doi.org/10.48550/arXiv.2507.23536URL:https://arxiv.org/abs/2507.23536. Acesso em: 13 jul. 2026.

[192] STANIFORD-CHEN, S.; CHEUNG, S.; CRAWFORD, R.; DILGER, M.; FRANK, J.; HOAGLAND, J.; LEVITT, K.; WEINTRAUB, C.; YIP, D.; ZERKLE, D. GrIDS — A Graph-Based Intrusion Detection System for Large Networks. In: Proc. of the 19th National Information Systems Security Conference (NISSC), 1996.. Disponível em: https://seclab.cs.ucdavis.edu/papers/nissc96.pdf. Acesso em: 13 jul. 2026.

[193] STOLFO, S. J.; FAN, W.; LEE, W.; PRODROMIDIS, A.; CHAN, P. K. Cost-based Modeling and Evaluation for Data Mining with Application to Fraud and Intrusion Detection. (KDD Cup 1999 background / TJ Watson Research), 2000.. Disponível em: https://kdd.ics.uci.edu/databases/kddcup99/task.html. Acesso em: 13 jul. 2026.

[194] SUI, Y.; ZHOU, M.; ZHOU, M.; HAN, S.; ZHANG, D. Table Meets LLM: Can Large Language Models Understand Structured Table Data? A Benchmark and Empirical Study. WSDM, 2024. arXiv:2305.13062. DOI: https://doi.org/10.48550/arXiv.2305.13062. Disponível em: https://arxiv.org/abs/2305.13062. Acesso em: 13 jul. 2026.

[195] TANG, J.; et al. (citado na literatura como "Long et al." em revisões derivadas). "Utilizing Large Language Models for Advanced Optimization and Intelligent Management in Space-Air-Ground Integrated Networks". IEEE Network, 2024.. Disponível em: https://doi.org/10.1109/MNET.2024.10806847https://ieeexplore.ieee.org/document/10806847/. Acesso em: 13 jul. 2026.

[196] TAVALLAEE, M.; BAGHERI, E.; LU, W.; GHORBANI, A. A. A Detailed Analysis of the KDD CUP 99 Data Set. In:

Proc. of the 2009 IEEE Symposium on Computational Intelligence in Security and Defense Applications (CISDA), 2009.. Disponível em: https://doi.org/10.1109/CISDA.2009.5356528URL:https://dl.acm.org/doi/10.5555/1736481.1736489. Acesso em: 13 jul. 2026.

[197] TOUVRON, Hugo; LAVRIL, Thibaut; IZACARD, Gautier; et al. (Meta AI). "LLaMA: Open and Efficient Foundation Language Models". arXiv preprint arXiv:2302.13971, 2023.. Disponível em: https://doi.org/10.48550/arXiv.2302.13971https://arxiv.org/abs/2302.13971. Acesso em: 13 jul. 2026.

[198] TOUVRON, Hugo; MARTIN, Louis; STONE, Kevin; et al. (Meta AI). "Llama 2: Open Foundation and Fine-Tuned Chat Models". arXiv preprint arXiv:2307.09288, 2023.. Disponível em: https://doi.org/10.48550/arXiv.2307.09288https://arxiv.org/abs/2307.09288. Acesso em: 13 jul. 2026.

[199] TOUVRON, H.; LAVRIL, T.; IZACARD, G.; MARTINET, X.; LACHAUX, M.-A.; LACROIX, T. et al. LLaMA: Open and Efficient Foundation Language Models. 2023. arXiv:2302.13971. DOI: https://doi.org/10.48550/arXiv.2302.13971. Disponível em: https://arxiv.org/abs/2302.13971. Acesso em: 13 jul. 2026.

[200] TOUVRON, H.; MARTIN, L.; STONE, K.; ALBERT, P.; ALMAHAIRI, A.; BABAEI, Y. et al. Llama 2: Open Foundation and Fine-Tuned Chat Models. 2023. arXiv:2307.09288.. Disponível em: https://doi.org/10.48550/arXiv.2307.09288URL:https://arxiv.org/abs/2307.09288. Acesso em: 13 jul. 2026.

[201] VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; et al. "Attention Is All You Need". Advances in Neural Information Processing Systems (NeurIPS), 2017.. Disponível em: https://doi.org/10.5555/3295222.3295349https://arxiv.org/abs/1706.03762. Acesso em: 13 jul. 2026.

[202] VELASCO, L.; MORALIS, F.; RUIZ, M.; et al. (via survey de Panayiotou et al. 2022). Cognitive/Data-driven Virtual Network Topology Reconfiguration. (Ver também: Panayiotou, T. et al. "Survey on Machine Learning for Traffic-Driven Service and Virtual Network Topology Reconfiguration," IEEE COMST, 2022 — https://arxiv.org/abs/2209.05080.). Disponível

em: https://arxiv.org/abs/2209.05080(surveydereferÃłncia);JOCN9(1):A35(artigo[34]acima).. Acesso em: 13 jul. 2026.

[203] WANG, S.; YE, K.; XU, C.-Z. Machine Learning in Network Anomaly Detection: A Survey. IEEE Access, v. 9, p. 152379–152396, 2021.. Disponível em: https://doi.org/10.1109/ACCESS.2021.3126834. Acesso em: 13 jul. 2026.

[204] WANG, K.; et al. (KTH). "NetConfEval: Can LLMs Facilitate Network Configuration?". Proceedings of the ACM on Networking / CoNEXT 2024, v. 2, p. 1–25.. Disponível em: https://doi.org/10.1145/3656296https://dl.acm.org/doi/10.1145/3656296. Acesso em: 13 jul. 2026.

[205] WANG, Z.; et al. (Minlan Yu group). "Intent-Driven Network Management with Multi-Agent LLMs". SIGCOMM 2025 (writeup).. Disponível em: https://minlanyu.seas.harvard.edu/writeup/sigcomm25.pdf. Acesso em: 13 jul. 2026.

[206] WEI, Jason; WANG, Xuezhi; SCHUURMANS, Dale; et al. "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models". arXiv preprint arXiv:2201.11903, 2022 (NeurIPS).. Disponível em: https://doi.org/10.48550/arXiv.2201.11903https://arxiv.org/abs/2201.11903. Acesso em: 13 jul. 2026.

[207] WEI, J.; WANG, X.; SCHUURMANS, D.; BOSMA, M.; ICHTER, B.; XIA, F.; CHI, E.; LE, Q.; ZHOU, D. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS, 2022. arXiv:2201.11903. DOI: https://doi.org/10.48550/arXiv.2201.11903. Disponível em: https://arxiv.org/abs/2201.11903. Acesso em: 13 jul. 2026.

[208] WILLEMS, D.; KOHLS, K.; VAN DER KAMP, B.; VRANKEN, H. Data Exfiltration Detection on Network Metadata with Autoencoders. Electronics (MDPI), v. 12, n. 12, p. 2584, 2023.. Disponível em: https://doi.org/10.3390/electronics12122584(OpenAccess) URL:https://www.mdpi.com/2079-9292/12/12/2584. Acesso em: 13 jul. 2026.

[209] XIA, W.; WEN, Y.; FOH, C. H.; NIYATO, D.; XIE, H. A Survey on Software-Defined Networking. IEEE Communications Surveys & Tutorials, v. 17, n. 1, p. 27–51, 2015.. Disponível em: https://doi.org/10.1109/COMST.2014.2330903. Acesso em: 13 jul. 2026.

[210] YANG, An; YANG, Baosong; et al. (Alibaba). "Qwen2.5 Technical Report". arXiv preprint arXiv:2412.15115, 2024.. Disponível em: https://doi.org/10.48550/arXiv.2412.15115https://arxiv.org/abs/2412.15115. Acesso em: 13 jul. 2026.

[211] YEGANEH, S. H.; GANJALI, Y. Kandoo: A Framework for Efficient and Scalable Offloading of Control Applications. ACM SIGCOMM HotSDN '12, p. 19–24, 2012.. Disponível em: https://doi.org/10.1145/2342441.2342446. Acesso em: 13 jul. 2026.

[212] YU, M.; REXFORD, J.; FREEDMAN, M. J.; WANG, J. Scalable Flow-Based Networking with DIFANE. ACM SIGCOMM 2010, p. 231–242, 2010.. Disponível em: https://doi.org/10.1145/1851182.1851224. Acesso em: 13 jul. 2026.

[213] ZHANG, M.; GUO, J.; LI, X.; JIN, R. Data-Driven Anomaly Detection Approach for Time-Series Streaming Data. Sensors (MDPI), v. 20, n. 19, p. 5646, 2020.. Disponível em: https://doi.org/10.3390/s20195646(OpenAccess)URL:https://pmc.ncbi.nlm.nih.gov/articles/PMC7582627/. Acesso em: 13 jul. 2026.

[214] ZHANG, Q.; CHEN, M.; BUKHARIN, A.; KARAMPATZIAKIS, N.; HE, P.; CHENG, Y.; CHEN, W.; ZHAO, T. AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning. ICLR, 2023. arXiv:2303.10512.. Disponível em: https://doi.org/10.48550/arXiv.2303.10512URL:https://arxiv.org/abs/2303.10512. Acesso em: 13 jul. 2026.

[215] ZHANG, R.; HAN, J.; LIU, C.; GAO, P.; ZHOU, A.; HU, X.; YAN, S.; LU, P.; LI, H.; QIAO, Y. LLaMA-Adapter: Efficient Fine-tuning of Language Models with Zero-init Attention. ICLR, 2024. arXiv:2303.16199.. Disponível em: https://doi.org/10.48550/arXiv.2303.16199URL:https://arxiv.org/abs/2303.16199. Acesso em: 13 jul. 2026.

[216] ZHANG, X.; CHOWDHURY, R. R.; GUPTA, R. K.; SHANG, J. Large Language Models for Time Series: A Survey. IJCAI, 2024. arXiv:2402.01801.. Disponível em: https://doi.org/10.48550/arXiv.2402.01801URL:https://arxiv.org/abs/2402.01801. Acesso em: 13 jul. 2026.

[217] ZHANG, Lingzhe; JIA, Tong; JIA, Mengxi; WU, Yifan; et al. "A Survey of AIOps in the Era of Large Language Models". ACM Computing Surveys, v. 58, n. 2, 2025 (arXiv:2507.12472).. Disponível em: https://doi.org/10.1145/3746635https://arxiv.org/abs/2507.12472. Acesso em: 13 jul. 2026.

[218] ZHANG, S.; DONG, L.; LI, X.; ZHANG, S.; SUN, X.; WANG, S. et al. Instruction Tuning for Large Language Models: A Survey. 2023 (atualizado 2025). arXiv:2308.10792. DOI: https://doi.org/10.48550/arXiv.2308.10792. Disponível em: https://arxiv.org/abs/2308.10792. Acesso em: 13 jul. 2026.